

Redes Neurais Informadas por Física (PINNs) versus Métodos de Diferenças Finitas (ADI) na Solução da Equação do Calor 2D em Domínios Irregulares

Autoria omitida para avaliação duplo-cega

Campus da Universidade Federal do Ceará em Quixadá

RESUMO

Este trabalho investiga o uso das Redes Neurais Informadas por Física (PINNs) aplicadas à solução numérica da Equação do Calor 2D transiente em geometrias irregulares, contrastando a sua eficácia com o tradicional método de Direções Alternadas Implícitas (ADI). Historicamente, métodos de Diferenças Finitas se destacam por sua eficiência $\mathcal{O}(N)$ devido à estruturação em matrizes tri-diagonais resolvidas pelo algoritmo de Thomas. No entanto, em um experimento envolvendo um domínio quadrado com orifícios circulares internos (atuando como sumidouros térmicos a $u = 0$), o ADI perde essa estrutura e sofre escadamento na fronteira. Demonstra-se que as PINNs convertem esse problema restritivo de malhas em uma abordagem *meshless* simplificada via diferenciação automática e penalização contínua. As funções de perda em subdomínios (condições de contorno multiobjetivo) asseguram o rigor físico contornando a malha algébrica, atingindo $\mathcal{L}_{\text{total}} \approx 10^{-4}$ ao término de 10.000 épocas e adaptando-se intrinsecamente às fronteiras curvas.

Palavras-chave: redes neurais informadas por física; equação do calor; método ADI; domínios irregulares; equações diferenciais parciais

ODS: indústria, inovação e infraestrutura

ABSTRACT

This work investigates the use of Physics-Informed Neural Networks (PINNs) applied to the numerical solution of the transient 2D Heat Equation in irregular geometries, contrasting its effectiveness with the traditional Alternating Direction Implicit (ADI) method. Historically, Finite Difference methods excel in $\mathcal{O}(N)$ efficiency due to the tridiagonal matrix structuring solved by the Thomas algorithm. However, in an experiment involving a square domain with internal circular holes (acting as heat sinks at $u = 0$), ADI loses this structure and suffers staircasing at the boundaries. We demonstrate that PINNs convert this restrictive mesh problem into a simplified meshless approach via automatic differentiation and continuous penalization. Subdomain loss functions (multi-objective boundary conditions) assure physical rigor circumventing algebraic meshing, reaching $\mathcal{L}_{\text{total}} \approx 10^{-4}$ after 10,000 epochs and intrinsically adapting to curved boundaries.

Keywords: physics-informed neural networks; heat equation; ADI method; irregular domains; partial differential equations

SDG: industry, innovation and infrastructure

1 INTRODUÇÃO

A modelagem de fenômenos físicos por equações diferenciais parciais (EDPs) sustenta a engenharia e as ciências aplicadas. Métodos numéricos clássicos — como Diferenças Finitas (MDF) e Volumes Finitos (MVF) — convertem operadores diferenciais contínuos em sistemas algébricos via discretização de malha estruturada ou não-estruturada. Dentre eles, o esquema de Direções Alternadas Implícitas

(ADI) [peaceman1955, pereira2019] consagrou-se como uma técnica altamente eficiente para EDPs parabólicas acopladas por fracionar problemas multidimensionais em subpassos de matrizes puramente tri-diagonais.

Embora consolidado, o método ADI enfrenta sérios desafios estruturais quando o domínio de interesse é irregular. Como ressaltado em [pereira2019], a eficiência extrema do algoritmo de Thomas sobre as matrizes do ADI degrada sensivelmente frente a furos circulares ou bordas curvas, os quais demandam malhas não-estruturadas, quebram o alinhamento ortogonal cartesiano e introduzem o erro geométrico de escadamento (*staircasing*).

Nesse contexto, a aproximação por redes neurais contínuas, impulsionada pelas *Physics-Informed Neural Networks* (PINNs) [raissi2019pinns], elimina o paradigma das malhas. As restrições físicas (resíduo da equação e condições de contorno em furos arbitrários) são inseridas diretamente na função de perda otimizada [karniadakis2021], utilizando diferenciação automática.

Este trabalho investiga a PINN aplicada à solução da Equação do Calor transiente 2D em um domínio perfurado por três buracos cilíndricos, contrastando a elegância topológica neural frente ao gargalo clássico de tri-diagonalização sofrido pelo método ADI.

2 DESENVOLVIMENTO

2.1 Fundamentação Teórica

Equação do Calor 2D em Domínio com Furos. A condução térmica transiente em sólido bidimensional com difusividade $\alpha > 0$ é governada pela equação parabólica:

$$\frac{\partial u}{\partial t} = \alpha \left(\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} \right), \quad (1)$$

operando sobre um domínio tempo-espacial modificado $(x, y, t) \in \Omega \times (0, 5, 0]$. Diferente dos problemas canônicos [pereira2019], Ω constitui o quadrado cartesiano unitário $[0, 1]^2$ subtraído de três regiões de orifício circular disjuntas $\mathcal{H}_1, \mathcal{H}_2, \mathcal{H}_3$. As condições impostas são: 1. Dirichlet Externo: $u|_{\partial\Omega_{\text{ext}}} = 1, 0$ 2. Dirichlet Interno (Sumidouros nos furos): $u|_{\partial\mathcal{H}_k} = 0, 0$ 3. Condição Inicial Nula: $u(\cdot, 0) = 0, 0$.

Método ADI e a Tri-Diagonalização de Thomas. A formulação de Peaceman-Rachford (ADI) em domínios estritamente retangulares divide o passo de tempo Δt na solução iterada e implícita de blocos:

$$\left(I - \frac{\alpha\Delta t}{2} \partial_{xx}^2\right) u^{n+1/2} = \left(I + \frac{\alpha\Delta t}{2} \partial_{yy}^2\right) u^n \quad \text{e} \quad \left(I - \frac{\alpha\Delta t}{2} \partial_{yy}^2\right) u^{n+1} = \left(I + \frac{\alpha\Delta t}{2} \partial_{xx}^2\right) u^{n+1/2} \quad (2)$$

As matrizes diferenciais $(I - \frac{\alpha\Delta t}{2} \partial^2)$ formam matrizes estruturadas contínuas e perfeitamente tri-diagonais. Tais sistemas alcançam resolução ótima com o algoritmo de Thomas [pereira2019]. Em presença dos orifícios curvos contudo, os vetores de adjacência perdem a continuidade nas vizinhanças dos nós cortados pelas fronteiras $\partial\mathcal{H}_k$, impondo extrapolações custosas e inibindo a complexidade de $\mathcal{O}(N)$.

Arquitetura Neural e Autograd (PINN). Para solucionar o paradigma, formula-se $\mathbf{u}_\theta \approx \mathbf{u}$ usando um MLP profundo $f_\theta : \mathbb{R}^3 \rightarrow \mathbb{R}$ com $L = 4$ camadas ocultas e $n = 64$ neurônios [raissi2019pinns]. A aproximação contínua assegura as diferenciações espaciais e temporais exatas utilizando modo reverso (*Autograd*):

$$\frac{\partial \mathbf{u}_\theta}{\partial x_j} = \nabla_{\mathbf{z}} \mathbf{u}_\theta \cdot \mathbf{e}_j, \quad \frac{\partial^2 \mathbf{u}_\theta}{\partial x_j^2} = \nabla_{\mathbf{z}} \left(\frac{\partial \mathbf{u}_\theta}{\partial x_j} \right) \cdot \mathbf{e}_j. \quad (3)$$

Otimização Multiobjetivo Meshless. Diferentemente de matrizes tridiagonais, o treinamento baseia-se na minimização espacial:

$$\mathcal{L}(\theta) = \mathcal{L}_{\text{pde}}(\theta) + \mathcal{L}_{\text{ic}}(\theta) + \mathcal{L}_{\text{bc_ext}}(\theta) + \mathcal{L}_{\text{bc_furos}}(\theta), \quad (4)$$

onde os orifícios não necessitam de malha para existirem, sendo apenas avaliados em um vetor de colocação polar N_b^{furos} centrado nas posições (x_c, y_c) dos respectivos buracos.

2.2 Metodologia

A Tabela ?? resume os hiperparâmetros. Os resíduos físicos N_f foram sorteados estocasticamente sob uma máscara de exclusão Euclidiana rigorosa $((x - x_c)^2 + (y - y_c)^2 > r^2)$.

Tabela 1 — Configuração experimental — Calor 2D (Furos) vs ADI Clássico.


Componente / Parâmetro	Especificação Adotada
Arquitetura PINN	MLP 4×64 , ativação tanh
Otimizador e Épocas	Adam, $\eta = 10^{-3}$ (10.000 épocas)
Amostragem Meshless	$N_f = 10.000$ (Domínio) / $N_{bc_ext} = 1.000$ / $N_{bc_furos} = 10.000$
Constantes Físicas	$\alpha = 0,01$, Tempos $t \in [0, 5, 0]$
Centros e Raios	$C_1(0,3,0,3)$, $C_2(0,7,0,3)$, $C_3(0,5,0,7)$ com $r = 0,12$
Desempenho Algoritmo Thomas	$\mathcal{O}(N)$ restrito estritamente a domínios regulares [pereira2019]

Fonte: Elaboração própria (versão identificada).

2.3 Resultados e Discussão

Convergência das Perdas em Contornos. A Figura ?? atesta que a rede assimilou corretamente a presença geométrica dos orifícios em poucas épocas. A função subobjetiva $\mathcal{L}_{bc_furos}$ estabilizou a penalidade próxima de zero em conformidade às paredes frias ($u = 0$), permitindo que $\mathcal{L}_{pde}$ convergisse com $\mathcal{L}_{total} \approx 10^{-4}$. Diferente do método ADI, onde a malha sofreria erro severo nas aproximações do contorno, a rede minimizou a penalidade sem instabilidade iterativa nas fronteiras não-alinhadas aos eixos cartesianos.

Figura 1 — Convergência semilogarítmica $\mathcal{L}$ (Loss) ao longo de 10.000 épocas (Calor Irregular).



Fonte: Elaboração própria (versão identificada).

Dinâmica e Conformidade em Subdomínio. A Figura ?? demonstra a difusividade térmica ao redor dos orifícios modelados pela PINN no instante $t = 0,8$. O gradiente perfeitamente concêntrico (sem escadeamentos quadriculados) em direção às zonas demarcadas corrobora com a eficácia do amostrador contínuo (meshless). Esta representação geométrica exata requereria pesadas rotinas no contexto das Diferenças Finitas e impediria a simplificação tri-diagonal direta.

3 CONSIDERAÇÕES FINAIS

A modelagem proposta reitera que esquemas MDF clássicos, notadamente o algoritmo implícito ADI, preservam máxima superioridade temporal na solução de matrizes regulares tri-diagonais. Em

Figura 2 — Evolução do Mapa de Calor 2D evidenciando o escape de calor perfeito para os orifícios ($t = 0,8$).



Fonte: Elaboração própria (versão identificada).

contrapartida, submetidos a perfurações contínuas, suas garantias algorítmicas de continuidade rompem-se. Neste cenário geométrico, as PINNs superaram os contornos com facilidade devido a propriedades analíticas de Autograd e amostragem escalar. Sugere-se como passo ulterior analisar a expansão desse *framework* para o acoplamento reativo (difusão-reação).