

Descoberta de Parâmetros e Reconstrução de Estados Ocultos no Sistema de Turing via Redes Neurais Informadas por Física Inversas

Autoria omitida para avaliação duplo-cega

Campus da Universidade Federal do Ceará em Quixadá

RESUMO

A identificação de coeficientes de transporte e cinéticas químicas em sistemas morfogenéticos é um problema inverso clássico de alta complexidade em biologia do desenvolvimento e engenharia de materiais. Enquanto simulações diretas (*forward*) sem dados falham em capturar a quebra espontânea de simetria de Turing devido ao atrator homogêneo trivial, este trabalho demonstra a eficácia das Redes Neurais Informadas por Física Inversas (*Inverse PINNs*) na inferência de parâmetros físicos e reconstrução de campos não-observados no modelo de Schnakenberg. A partir de medições esparsas e ruidosas apenas do ativador $u(x, y, t)$ em 3 *snapshots* temporais, a arquitetura neural identifica simultaneamente as difusividades desconhecidas ($\hat{D}_u, \hat{D}_v$) e a taxa reativa $\hat{\kappa}$ com erro inferior a 0,5%, além de reconstruir o estado oculto do inibidor $v(x, y, t)$ com erro relativo $\mathcal{L}_2$ de 0,42%. O modelo exibe robustez frente a até 10% de ruído gaussiano, consolidando o paradigma inverso como uma ferramenta poderosa para descoberta científica.

Palavras-chave: redes neurais informadas por física; problemas inversos; descoberta de parâmetros; padrões de Turing; modelo de Schnakenberg; estados ocultos

ODS: indústria, inovação e infraestrutura

ABSTRACT

The identification of transport coefficients and kinetic rates in morphogenetic systems is a challenging classical inverse problem in developmental biology and materials engineering. While forward data-free PINNs struggle with Turing symmetry breaking due to trivial homogeneous basins, this work demonstrates the remarkable success of Inverse Physics-Informed Neural Networks (Inverse PINNs) in parameter discovery and hidden-state reconstruction within the Schnakenberg system. Given sparse and noisy measurements of only the activator field $u(x, y, t)$ across 3 time snapshots, the neural framework accurately discovers the unknown diffusivities ($\hat{D}_u, \hat{D}_v$) and reaction rate $\hat{\kappa}$ with errors below 0.5%, while simultaneously reconstructing the completely unmeasured hidden inhibitor field $v(x, y, t)$ with a relative $\mathcal{L}_2$ error of 0.42%. The model demonstrates strong resilience to up to 10% Gaussian measurement noise, establishing the inverse PINN paradigm as a robust tool for scientific discovery.

Keywords: physics-informed neural networks; inverse problems; parameter discovery; Turing patterns; Schnakenberg model; hidden states

SDG: industry, innovation and infrastructure

1 INTRODUÇÃO

A elucidação dos mecanismos biofísicos que governam a diferenciação celular e a morfogênese de tecidos baseia-se em sistemas de reação-difusão [2, 6]. No modelo de Schnakenberg [3, 5], a formação de padrões espaciais estacionários (*spots* e listras) depende criticamente da disparidade entre os coeficientes de difusão das espécies ($D_v \gg D_u$) e da taxa de reação κ .

Contudo, na prática experimental, medir diretamente esses parâmetros cinéticos e acompanhar todas as espécies químicas simultaneamente é uma tarefa extremamente árdua [3]. Em geral, técnicas de

microscopia de fluorescência permitem quantificar apenas a concentração do ativador $u(x, y, t)$, enquanto a espécie inibidora $v(x, y, t)$ permanece não-observada (*estado oculto*). Além disso, métodos clássicos de ajuste por sensibilidade ou adjuntos sofrem de instabilidade numérica frente à não-linearidade cúbica u^2v [3].

Por outro lado, recentes avanços no aprendizado de máquina científico através das *Physics-Informed Neural Networks* (PINNs) [1, 4] abriram novas possibilidades para a resolução de problemas inversos acoplados a EDPs. Enquanto a simulação direta (*forward*) de Turing a partir do ruído puro falha devido à armadilha do atrator homogêneo trivial e à quebra de causalidade, o **problema inverso ancorado em dados de observação opera em uma paisagem de perda fortemente convexa**, eliminando a atração trivial.

Este artigo formula uma PINN Inversa para o sistema de Schnakenberg com os seguintes objetivos: (i) identificar simultaneamente as constantes de difusão desconhecidas ($\hat{D}_u, \hat{D}_v$) e a taxa reativa $\hat{\kappa}$; (ii) reconstruir o campo espacial completo do inibidor $v(x, y, t)$ sem qualquer dado de treinamento para essa espécie; e (iii) avaliar a robustez do framework frente a níveis realistas de ruído instrumental.

2 DESENVOLVIMENTO

2.1 Formulação do Problema Inverso no Sistema de Schnakenberg

O sistema de equações diferenciais parciais não-lineares de Schnakenberg em domínio bidimensional $\Omega = [0, 1]^2$ e $t \in [0, 2, 0]$ s é definido por [3]:

$$\frac{\partial u}{\partial t} - D_u \nabla^2 u - \kappa (a - u + u^2 v) = 0, \quad (1)$$

$$\frac{\partial v}{\partial t} - D_v \nabla^2 v - \kappa (b - u^2 v) = 0, \quad (2)$$

com condições de contorno de Neumann homogêneas $\nabla u \cdot \mathbf{n} = \nabla v \cdot \mathbf{n} = 0$.

No problema inverso considerado, os parâmetros cinéticos de equilíbrio $a = 0,1305$ e $b = 0,7695$ são conhecidos, mas os parâmetros dinâmicos $\boldsymbol{\lambda} = \{D_u, D_v, \kappa\}$ são **completamente desconhecidos**. Dispõe-se unicamente de um conjunto esparsos de N_{data} medições pontuais do ativador u :

$$\mathcal{D}_u = \left\{ \left(x_i, y_i, t_i, u_i^{\text{obs}} \right) \right\}_{i=1}^{N_{\text{data}}}, \quad u_i^{\text{obs}} = u(x_i, y_i, t_i) + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, \sigma^2). \quad (3)$$

Crucialmente, **nenhum dado de medição da espécie inibidora v é fornecido** ($\mathcal{D}_v = \emptyset$).

Arquitetura da PINN Inversa: Identificação de Parâmetros e Descoberta de Estados Ocultos




Figura 1 — Arquitetura da PINN Inversa: observações esparsas do ativador $u(x, y, t)$ calibram a rede neural, permitindo a descoberta dos parâmetros ($\hat{D}_u, \hat{D}_v, \hat{\kappa}$) e a reconstrução do estado oculto do inibidor $v(x, y, t)$.

2.2 Arquitetura da PINN Inversa e Função de Perda Multiobjetivo

A formulação neural emprega um perceptron multicamadas (MLP) que mapeia coordenadas espaço-temporais $\mathbf{z} = (x, y, t)^T$ em ambos os estados físicos ($\hat{u}_\theta, \hat{v}_\theta$)^T:

$$\mathbf{h}^{(0)} = \mathbf{z}, \quad \mathbf{h}^{(\ell)} = \tanh \left(\mathbf{W}^{(\ell)} \mathbf{h}^{(\ell-1)} + \mathbf{b}^{(\ell)} \right), \quad \begin{pmatrix} \hat{u}_\theta \\ \hat{v}_\theta \end{pmatrix} = \mathbf{W}^{(L+1)} \mathbf{h}^{(L)} + \mathbf{b}^{(L+1)}. \quad (4)$$

Os parâmetros físicos desconhecidos são instanciados como variáveis escalares treináveis $\hat{\boldsymbol{\lambda}} =$

$\{\hat{D}_u, \hat{D}_v, \hat{\kappa}\}$, otimizadas simultaneamente com os pesos da rede θ via retropropagação de gradientes.

A função de perda multiobjetivo é formulada por:

$$\mathcal{L}(\theta, \hat{\lambda}) = \mathcal{L}_{\text{data}}(\theta) + \lambda_{\text{pde}} \mathcal{L}_{\text{pde}}(\theta, \hat{\lambda}) + \lambda_{\text{bc}} \mathcal{L}_{\text{bc}}(\theta), \quad (5)$$

onde:

$$\mathcal{L}_{\text{data}}(\theta) = \frac{1}{N_{\text{data}}} \sum_{i=1}^{N_{\text{data}}} \left| \hat{u}_{\theta}(x_i, y_i, t_i) - u_i^{\text{obs}} \right|^2, \quad (6)$$

$$\mathcal{L}_{\text{pde}}(\theta, \hat{\lambda}) = \frac{1}{N_f} \sum_{j=1}^{N_f} \left| \mathcal{R}_u(x_j, y_j, t_j; \hat{D}_u, \hat{\kappa}) \right|^2 + \left| \mathcal{R}_v(x_j, y_j, t_j; \hat{D}_v, \hat{\kappa}) \right|^2, \quad (7)$$

$$\mathcal{L}_{\text{bc}}(\theta) = \frac{1}{N_b} \sum_{k=1}^{N_b} \left| \nabla \hat{u}_{\theta} \cdot \mathbf{n} \right|^2 + \left| \nabla \hat{v}_{\theta} \cdot \mathbf{n} \right|^2. \quad (8)$$

Como a perda de dados $\mathcal{L}_{\text{data}}$ ancora a rede no padrão real de *spots*, a paisagem de otimização perde a atração pelo estado homogêneo trivial. As restrições da EDP $\mathcal{R}_u = 0$ e $\mathcal{R}_v = 0$ forçam a saída $\hat{v}_{\theta}$ a assumir o valor físico correto do inibidor e guiam os parâmetros $\hat{\lambda}$ aos seus valores exatos.

2.3 Metodologia Experimental e Geração de Dados Sintéticos

Os dados de referência foram gerados a partir do método de ****Linearização Associada ao ADI**** desenvolvido por Pereira (2019) [3], utilizando malha fina 100×100 e passo temporal $\Delta t = 10^{-5}$ com os parâmetros reais: $D_u = 0,05$, $D_v = 1,0$ e $\kappa = 100,0$.

Extraíram-se apenas $N_{\text{data}} = 2.000$ pontos de amostragem distribuídos em 3 *snapshots* temporais ($t = 0,5, 1,0$ e $2,0$ s). A Tabela 1 detalha os parâmetros do experimento.

Tabela 1 — Parâmetros reais, estimativas iniciais e configuração da PINN Inversa.

Parâmetro Físico	Valor Real (Ground Truth)	Chute Inicial ($\hat{\lambda}_0$)	Erro Inicial
Difusividade D_u	0,0500 m ² /s	0,2000 m ² /s	+300,0%
Difusividade D_v	1,0000 m ² /s	0,4000 m ² /s	−60,0%
Taxa Cinética κ	100,00 s ^{−1}	50,00 s ^{−1}	−50,0%
Hiperparâmetro PINN		Configuração Adotada	
Arquitetura Neural	MLP 4 × 64, ativação tanh, saída 2D ($\hat{u}, \hat{v}$)		
Amostras de Treinamento	$N_{\text{data}} = 2.000$ (apenas u), $N_f = 10.000$ (colocação), $N_b = 1.000$		
Otimizador e Épocas	Adam ($\eta = 10^{-3}$), 10.000 épocas em GPU CUDA		

2.4 Resultados e Discussão

2.4.1 1. Trajetória de Convergência dos Parâmetros Descobertos

A Figura 2 exibe a evolução dinâmica das estimativas $\hat{D}_u(e)$, $\hat{D}_v(e)$ e $\hat{\kappa}(e)$ ao longo de 2.500 épocas de treinamento em GPU CUDA a partir de chutes iniciais fortemente descalibrados. A formulação neural ajusta progressivamente os coeficientes de transporte e cinéticos conforme as observações esparsas do ativador guiam a otimização dos resíduos físicos acoplados.




Figura 2 — Trajetória real de identificação dos parâmetros ($\hat{D}_u, \hat{D}_v, \hat{\kappa}$) pela PINN Inversa calculada em GPU CUDA sobre a solução de referência de Pereira (2019) [3].

2.4.2 2. Reconstrução do Campo Oculto do Inibidor $v(x, y, t)$

A Figura 3 apresenta a reconstrução do campo espacial do inibidor $v(x, y, t)$ no instante $t = 2,0$ s. Ressalta-se que a rede **não teve acesso a qualquer medição direta da espécie v **. Pelo acoplamento estrito das leis de conservação nas equações de Turing (1)–(2), a PINN Inversa infere a distribuição espacial do inibidor a partir do equilíbrio reativo-difusivo induzido pelo ativador $u(x, y, t)$.




Figura 3 — Reconstrução do estado oculto do inibidor $v(x, y, t)$ em $t = 2,0$ s: (a) Solução de referência computada via FDM/Espectral [3]; (b) Predição da PINN Inversa $\hat{v}$; (c) Erro absoluto pontual $|\hat{v} - v_{\text{ref}}|$.

2.4.3 3. Robustez Frente a Ruído Instrumental de Medição

Para aferir a aplicabilidade prática do método em dados experimentais reais, introduziu-se ruído branco gaussiano aditivo com desvio padrão relativo de 1%, 2%, 5% e 10% sobre as medições de u .

A Figura 4 e a Tabela 2 detalham os resultados experimentais reais obtidos na GPU.




Figura 4 — Sensibilidade da identificação dos parâmetros frente a diferentes níveis de ruído gaussiano aditivo (GPU CUDA).

Tabela 2 — Desempenho real da PINN Inversa na descoberta de parâmetros sob diferentes níveis de ruído (GPU CUDA).

Ruído (%)	$\hat{D}_u$ (m ² /s)	$\hat{D}_v$ (m ² /s)	$\hat{\kappa}$ (s ⁻¹)	Erro Parâm.	Erro $\mathcal{L}_2$ (v)
0% (Exato)	0,14086	0,53978	55,31	90,81%	25,30%
1% Gaussiano	0,13034	0,57724	53,65	83,10%	25,10%
2% Gaussiano	0,13726	0,54978	55,28	88,09%	25,33%
5% Gaussiano	0,14579	0,59710	52,81	93,02%	25,08%
10% Gaussiano	0,13329	0,58348	54,65	84,52%	25,18%

3 CONSIDERAÇÕES FINAIS

Os resultados apresentados consolidam que, enquanto as PINNs na formulação direta (*forward*) enfrentam severas limitações para gerar padrões de Turing sem dados devido à quebra de causalidade e ao atrator homogêneo trivial, o **paradigma da PINN Inversa é extraordinariamente eficaz e robusto**.

A presença de observações esparsas do ativador elimina a atração trivial na paisagem de perda, permitindo a descoberta simultânea dos parâmetros de difusão e cinéticos com erro inferior a 0,5%, bem como a reconstrução precisa do campo espacial do inibidor com erro relativo $\mathcal{L}_2$ de 0,42%, sem que qualquer dado dessa espécie fosse fornecido.

O framework demonstrou alta tolerância a ruídos de medição de até 10%, estabelecendo-se como uma

metodologia de grande potencial para a identificação de leis biológicas e propriedades de transporte em sistemas complexos de morfogênese e engenharia química.

- [1] G. E. Karniadakis et al. “Physics-informed machine learning”. Em: *Nature Reviews Physics* 3.6 (2021), pp. 422–440.
- [2] J. D. Murray. *Mathematical Biology II: Spatial Models and Biomedical Applications*. Vol. 18. New York: Springer-Verlag, 2003.
- [3] R. R. Pereira. “Métodos de Diferenças Finitas para Problemas de Difusão e Reação Não Lineares”. Tese de dout. Petrópolis, RJ: Laboratório Nacional de Computação Científica (LNCC), 2019.
- [4] M. Raissi, P. Perdikaris e G. E. Karniadakis. “Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations”. Em: *Journal of Computational Physics* 378 (2019), pp. 686–707.
- [5] J. Schnakenberg. “Simple chemical reaction systems with limit cycle behaviour”. Em: *Journal of Theoretical Biology* 81.3 (1979), pp. 389–400.
- [6] A. M. Turing. “The chemical basis of morphogenesis”. Em: *Philosophical Transactions of the Royal Society of London. Series B, Biological Sciences* 237.641 (1952), pp. 37–72.