

Limites de Redes Neurais Informadas por Física na Formação de Padrões de Turing: Análise das Patologias de Otimização e a Eficácia do ADI Linearizado

Autoria omitida para avaliação duplo-cega

Campus da Universidade Federal do Ceará em Quixadá

RESUMO

Este trabalho investiga os limites teóricos e computacionais das Redes Neurais Informadas por Física (PINNs) baseadas em Perceptron Multicamadas (MLP) *vanilla* na simulação direta da formação de padrões de Turing no modelo de reação-difusão de Schnakenberg bidimensional. Demonstra-se que, embora as PINNs possuam capacidade universal de representação, a otimização por gradiente colapsa catastroficamente para o estado homogêneo estacionário, produzindo uma falsa convergência com resíduos aparentemente baixos ($\mathcal{L}_{\text{total}} \sim 10^{-2}$) sem qualquer quebra de simetria espacial. Identificam-se quatro patologias estruturais responsáveis pelo insucesso: o aprisionamento no atrator trivial homogêneo, a quebra de causalidade temporal na amostragem espaço-tempo global, o viés espectral da MLP contra o número de onda crítico k_c e a rigidez numérica induzida pela alta taxa cinética ($\gamma = 1000$) e assimetria difusiva ($D_v/D_u = 10$). Em contrapartida, o método de Direções Alternadas Implícitas (ADI) com linearização de reação, formulado por Pereira (2019), resolve estavelmente a evolução temporal das manchas com convergência $\mathcal{O}(\Delta t^2)$, preservando a amplificação exponencial dos modos instáveis em reduzido tempo computacional.

Palavras-chave: redes neurais informadas por física; instabilidade de Turing; sistema de Schnakenberg; direções alternadas implícitas; viés espectral; aprendizado de máquina científico

ODS: indústria, inovação e infraestrutura

ABSTRACT

This work investigates the theoretical and computational limits of standard (vanilla) Multilayer Perceptron (MLP) Physics-Informed Neural Networks (PINNs) in simulating forward Turing pattern formation within the two-dimensional Schnakenberg reaction-diffusion model. We demonstrate that despite the universal approximation theorem, gradient descent optimization catastrophically collapses into the trivial homogeneous steady state, yielding deceitfully low residual losses ($\mathcal{L}_{\text{total}} \sim 10^{-2}$) while completely failing to undergo spatial symmetry breaking. We identify four core optimization pathologies: the trivial homogeneous attractor trap, temporal causality breakdown under global space-time collocation, spectral bias against critical Turing wavenumbers k_c , and severe numerical stiffness driven by large kinetic rates ($\gamma = 1000$) and diffusivity ratios ($D_v/D_u = 10$). In contrast, the classical Linearized Alternating Direction Implicit (ADI) finite difference scheme developed by Pereira (2019) robustly captures spot pattern morphogenesis with unconditional stability, strict temporal causality, and $\mathcal{O}(\Delta t^2)$ convergence.

Keywords: physics-informed neural networks; Turing instability; Schnakenberg system; alternating direction implicit; spectral bias; scientific machine learning

SDG: industry, innovation and infrastructure

1 INTRODUÇÃO

A auto-organização espacial a partir de meios inicialmente homogêneos constitui um dos pilares da biologia matemática e da termodinâmica fora do equilíbrio. Em seu trabalho seminal, Alan Turing [6] estabeleceu que a combinação de reações químicas não-lineares e taxas desiguais de difusão molecular

pode desestabilizar um estado uniforme estacionário — estável na ausência de transporte — gerando estruturas espaciais periódicas permanentes (manchas, listras e labirintos) [1].

A simulação computacional clássica desses sistemas de reação-difusão baseia-se em Métodos de Diferenças Finitas (MDF), Volumes Finitos (MVF) e Elementos Finitos (MEF). Conforme amplamente explorado na tese de doutorado de Pereira [2], esquemas numéricos avançados como a técnica de Direções Alternadas Implícitas (ADI) e a Decomposição de Operadores (*Operator Splitting*) permitem desacoplar a rigidez cinética e as derivadas espaciais, garantindo estabilidade incondicional e convergência de segunda ordem.

Paralelamente, o paradigma das *Physics-Informed Neural Networks* (PINNs) [4] emergiu como uma abordagem contínua e livre de malha (*meshless*) para equações diferenciais parciais (EDPs), integrando resíduos diferenciais na função de perda via diferenciação automática (*Autograd*). Contudo, embora as PINNs tenham alcançado êxito em regimes puramente difusivos ou advectivos suaves, sua aplicação à simulação temporal direta (*forward problem*) de instabilidades de Turing enfrenta falhas catastróficas: redes MLP *vanilla* colapsam invariavelmente para campos planos uniformes, sem manifestar quebra de simetria.

Este artigo analisa rigorosamente as causas matemáticas e algorítmicas dessa incapacidade, fundamentando as quatro patologias de otimização das PINNs *vanilla* no modelo de Schnakenberg [5] e contrastando-as com o sucesso do esquema ADI linearizado desenvolvido por Pereira [2].

2 DESENVOLVIMENTO

2.1 O Sistema de Schnakenberg e Análise de Estabilidade Linear

O sistema de reação-difusão proposto por Schnakenberg [5] modela a cinética autocatalítica entre um ativador $u(x, y, t)$ e um inibidor $v(x, y, t)$ em $\Omega = [0, 1]^2$:

$$\frac{\partial u}{\partial t} = D_u \nabla^2 u + \gamma(a - u + u^2 v), \quad (1)$$

$$\frac{\partial v}{\partial t} = D_v \nabla^2 v + \gamma(b - u^2 v), \quad (2)$$

onde $D_u, D_v > 0$ são os coeficientes de difusão, $\gamma > 0$ é a escala cinética, e $a, b > 0$ são constantes. O sistema é sujeito a condições de Neumann homogêneas: $\nabla u \cdot \mathbf{n} = \nabla v \cdot \mathbf{n} = 0$ em $\partial\Omega$.

O estado de equilíbrio homogêneo (u^*, v^*) na ausência de difusão ($\nabla^2 u = \nabla^2 v = 0$) é $u^* = a + b$ e $v^* = b/(a + b)^2$. A matriz Jacobiana das reações no ponto fixo é:

$$J = \begin{pmatrix} f_u & f_v \\ g_u & g_v \end{pmatrix}_{(u^*, v^*)} = \begin{pmatrix} \frac{b-a}{a+b} & (a+b)^2 \\ -\frac{2b}{a+b} & -(a+b)^2 \end{pmatrix}. \quad (3)$$

Para que o estado homogêneo seja estável sob a cinética puramente temporal, exige-se $\text{Tr}(J) = f_u + g_v < 0$ e $\det(J) = (a + b)^2 > 0$.

A instabilidade de Turing ocorre quando a perturbação espacial $\propto \cos(n_x \pi x) \cos(n_y \pi y) e^{\lambda(k^2)t}$ com número de onda $k^2 = (n_x \pi)^2 + (n_y \pi)^2$ torna o polinômio característico $\det(\lambda I - J_k) = 0$ negativo, onde $J_k = \gamma J - k^2 \text{diag}(D_u, D_v)$. Isso requer $D_v f_u + D_u g_v > 0$ ($D_v/D_u \gg 1$) e a existência de uma raiz onde $h(k^2) \equiv \det(J_k) = D_u D_v k^4 - \gamma(D_v f_u + D_u g_v)k^2 + \gamma^2 \det(J) < 0$. A taxa de crescimento máxima $\lambda(k^2) > 0$ ocorre no número de onda crítico:

$$k_{\text{crit}}^2 = \frac{\gamma(D_v f_u + D_u g_v)}{2D_u D_v}. \quad (4)$$

Adotando os parâmetros clássicos de Murray [1, 2]: $a = 0,1305$, $b = 0,7739$, $D_u = 1,0$, $D_v = 10,0$ e $\gamma = 1000,0$, obtém-se o ponto fixo $u^* \approx 0,9045$, $v^* \approx 0,9461$, $k_{\text{crit}}^2 \approx 314,8$ e a faixa instável $k^2 \in [183,2; 446,4]$ com taxa máxima $\lambda_{\text{max}} \approx 2,18$.

2.2 Arcabouço PINN e Patologias de Otimização


Na formulação PINN [4], aproxima-se (u, v) por uma rede $\mathbf{u}_\theta(t, x, y) = \mathbf{W}^{(L+1)}\mathbf{h}^{(L)} + \mathbf{b}^{(L+1)}$, com $\mathbf{h}^{(\ell)} = \tanh(\mathbf{W}^{(\ell)}\mathbf{h}^{(\ell-1)} + \mathbf{b}^{(\ell)})$. As derivadas são calculadas por *Autograd* e a perda multiobjetivo é:

$$\mathcal{L}(\theta) = \mathcal{L}_{\text{pde}}(\theta) + \lambda_{\text{bc}}\mathcal{L}_{\text{bc}}(\theta) + \lambda_{\text{ic}}\mathcal{L}_{\text{ic}}(\theta), \quad (5)$$

$$\mathcal{L}_{\text{pde}} = \frac{1}{N_f} \sum_{i=1}^{N_f} (\|\mathcal{R}_u(t_i, x_i, y_i)\|^2 + \|\mathcal{R}_v(t_i, x_i, y_i)\|^2), \quad \mathcal{L}_{\text{bc}} = \frac{1}{N_b} \sum_{j=1}^{N_b} (|\partial_{\mathbf{n}}u|^2 + |\partial_{\mathbf{n}}v|^2). \quad (6)$$

A Figura 1 resume a arquitetura neural e formaliza as quatro patologias fundamentais que causam o fracasso sistemático da PINN *vanilla*:

Figura 1 — Arquitetura da PINN para o sistema de Schnakenberg 2D e diagrama esquemático das quatro patologias de otimização que causam a falha de bifurcação.



Fonte: Elaboração própria (versão identificada).

- 1. Falso Atrator Homogêneo:** Se a rede prediz a constante (u^*, v^*) , tem-se $\partial_t u = \nabla^2 u = f(u^*, v^*) = 0 \implies \mathcal{L}_{\text{pde}} \equiv 0$ e $\mathcal{L}_{\text{bc}} \equiv 0$. Para perturbação inicial microscópica $\delta u \sim 10^{-3}$, a perda total é ínfima ($\mathcal{L}_{\text{total}} \approx \mathcal{L}_{\text{ic}} \sim 10^{-6}$). O gradiente converge para este atrator trivial sem bifurcar.
- 2. Quebra de Causalidade Temporal:** A amostragem global em $\Omega \times [0, T]$ avalia resíduos em $t = T$ simultaneamente com $t = 0$. Os gradientes em tempos tardios forçam médias espaciais que amortecem a amplificação das oscilações em $t \approx 0$ [7].
- 3. Viés Espectral (Spectral Bias):** Redes MLP com ativações analíticas suaves aprendem baixas frequências espaciais com velocidade exponencialmente superior às altas [3]. O modo crítico $k_{\text{crit}} \approx 17,7$ é suprimido pelo filtro passa-baixo natural da rede.
- 4. Rigidez Cinética Extrema:** O parâmetro $\gamma = 1000$ impõe $\tau_{\text{react}} \sim 10^{-3} \ll \tau_{\text{diff}} \sim 0,1$. No gradiente $\nabla_{\theta} \mathcal{L}_{\text{pde}}$, a cinética domina sobre a difusão por $10^3 \times$, forçando $f = g = 0$ antes que o transporte difusivo estruture o padrão espacial.

2.3 Esquema Numérico Robusto: ADI Linearizado (Pereira, 2019)

Para superar a severa rigidez do modelo de Schnakenberg, Pereira [2] formulou uma extensão do esquema de Peaceman-Rachford com linearização das reações no passo intermediário $t^{n+1/2}$. Dividindo o Laplaciano em operadores unidirecionais δ_x^2 e δ_y^2 :

$$\left(I - \frac{D_u \Delta t}{2} \delta_x^2\right) u^{n+1/2} = \left(I + \frac{D_u \Delta t}{2} \delta_y^2\right) u^n + \frac{\gamma \Delta t}{2} \tilde{f}^{n+1/2}, \quad (7)$$

$$\left(I - \frac{D_u \Delta t}{2} \delta_y^2\right) u^{n+1} = \left(I + \frac{D_u \Delta t}{2} \delta_x^2\right) u^{n+1/2} + \frac{\gamma \Delta t}{2} \tilde{f}^{n+1/2}, \quad (8)$$

com previsões linearizadas fechadas $\tilde{f}^{n+1/2}$ e $\tilde{g}^{n+1/2}$ [2]. O esquema resulta em sistemas estritamente tridiagonais resolvidos pelo Algoritmo de Thomas com complexidade $\mathcal{O}(N)$, garantindo estabilidade incondicional e convergência $\mathcal{O}(\Delta t^2 + \Delta x^2)$.

2.4 Resultados Experimentais e Discussão

A Tabela 1 compara a configuração da PINN *vanilla* e do resolvidor ADI clássico de Pereira (2019).


Tabela 1 — Configuração comparativa entre a PINN *vanilla* e o esquema ADI Linearizado.

Parâmetro / Aspecto	PINN Vanilla (MLP)	ADI Linearizado [2]
Arquitetura / Discretização	MLP 4 camadas $\times$ 64 neurônios, tanh	Malha uniforme 80×80 , Thomas $\mathcal{O}(N)$
Domínio e Condições de Contorno	$[0, 1]^2 \times [0, 10]$, Neumann homogêneo	$[0, 1]^2 \times [0, 10]$, Neumann homogêneo
Parâmetros Físicos	$a = 0,1305, b = 0,7739, \gamma = 1000$	$a = 0,1305, b = 0,7739, \gamma = 1000$
Difusividades (D_u, D_v)	$D_u = 1,0, D_v = 10,0$	$D_u = 1,0, D_v = 10,0$
Passo Temporal / Pontos	$N_f = 10^4, N_b = 10^3, N_0 = 10^3$	$\Delta t = 10^{-4}$ (marcha estritamente causal)
Tratamento Não-linear	Penalização global via <i>Autograd</i>	Linearização de Taylor em $t^{n+1/2}$
Tempo de Processamento	~ 18 minutos (GPU)	7,41 segundos (CPU)

Fonte: Elaboração própria (versão identificada).

A Figura 2a exibe a relação de dispersão teórica $\lambda(k^2)$ com a banda instável $[183,2; 446,4]$ e pico em $k_{\text{crit}}^2 \approx 314,8$. Na Figura 2b, a curva de treinamento semilogarítmica da PINN demonstra que as perdas $\mathcal{L}_{\text{pde}}$ e $\mathcal{L}_{\text{total}}$ estacionam no platô de $\approx 1,2 \times 10^{-2}$, caracterizando a estagnação no atrator trivial sem formação de manchas.


Figura 2 — Dinâmica de instabilidade e convergência: (a) Relação de dispersão de Turing $\lambda(k^2)$ com banda instável; (b) Curvas de perda da PINN com falso platô.



Fonte: Elaboração própria (versão identificada).

A Figura 3 ilustra a evolução espaçotemporal obtida pelo método ADI linearizado [2] sob perturbação gaussiana localizada $u_0 = u^* + 10^{-3} \exp[-100((x - 1/3)^2 + (y - 1/2)^2)]$. Observa-se a propagação radial das frentes de onda e a subsequente maturação para um arranjo periódico hexagonal de manchas.


Figura 3 — Evolução espaçotemporal do ativador $u(x, y, t)$ via esquema ADI Linearizado [2] a partir de perturbação pontual em $t \in [0,02; 2,00]$.



Fonte: Elaboração própria (versão identificada).

A Figura 4 sintetiza o confronto direto no instante $t = 10,0$. Enquanto o ADI atinge o estado estacionário estruturado com amplitude $u \in [0,3; 2,3]$, a PINN colapsa no campo perfeitamente plano $u_\theta \approx 0,9045$. O mapa de erro absoluto atinge magnitude $\mathcal{O}(1)$, comprovando que resíduos de perda de $\approx 10^{-2}$ ocultam um erro físico completo na detecção da morfogênese.

Figura 4 — Comparação no estado assintótico $t = 10,0$: (a) Referência ADI/MDF [2]; (b) Predição da PINN *vanilla*; (c) Mapa de erro absoluto $|u_{\text{pinn}} - u_{\text{ref}}|$.



Fonte: Elaboração própria (versão identificada).

A Tabela 2 consolida os indicadores de desempenho final.

Tabela 2 — Comparativo quantitativo de desempenho e resolução física ($t = 10,0$).

Métrica de Avaliação	PINN Vanilla (MLP)	ADI Linearizado [2]
Perda Residual Final ($\mathcal{L}_{\text{total}}$)	$1,24 \times 10^{-2}$	— (Discretização Direta)
Erro Relativo $\mathcal{L}_2$ frente ao Padrão	78,4%	$< 10^{-3}$ (Validação de Malha)
Amplitude Espacial $\Delta u = u_{\text{max}} - u_{\text{min}}$	0,008 (Uniforme)	2,02 (Manchas Hexagonais)
Preservação da Causalidade Temporal	Não (Colocação Global)	Sim (Marcha $\Delta t = 10^{-4}$)
Desfecho Físico	Falha Crítica (Sem Padrão)	Sucesso Robusto (Padrão Nítido)

Fonte: Elaboração própria (versão identificada).

3 CONSIDERAÇÕES FINAIS

Os resultados comprovam que a incapacidade das PINNs *vanilla* em simular a formação direta de padrões de Turing decorre de patologias severas na paisagem de otimização: o atrator homogêneo trivial aprisiona o gradiente, a colocação global suprime a causalidade física, o viés espectral filtra o modo crítico k_c e a rigidez $\gamma \gg 1$ desequilibra a dinâmica de treinamento. Em nítido contraste, métodos clássicos de diferenças finitas como o ADI linearizado de Pereira [2] integram a marcha temporal respeitando a causalidade e a estabilidade incondicional com custo computacional desprezível ($\approx 7,4$ s). Para que modelos neurais superem essas limitações em bifurcações, torna-se imperativo adotar ponderação causal exponencial [7], formulações discretas no tempo ou métodos de continuação de parâmetros.

REFERÊNCIAS

- [1] J. D. Murray. *Mathematical Biology II: Spatial Models and Biomedical Applications*. Vol. 18. Interdisciplinary Applied Mathematics. New York: Springer-Verlag, 2003.
- [2] R. R. Pereira. “Métodos de Diferenças Finitas para Problemas de Difusão e Reação Não Lineares”. Tese de dout. Petrópolis, RJ: Laboratório Nacional de Computação Científica (LNCC), 2019.
- [3] N. Rahaman et al. “On the Spectral Bias of Neural Networks”. Em: *Proceedings of the 36th International Conference on Machine Learning*. Vol. 97. PMLR, 2019, pp. 5301–5310.
- [4] M. Raissi, P. Perdikaris e G. E. Karniadakis. “Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations”. Em: *Journal of Computational Physics* 378 (2019), pp. 686–707.
- [5] J. Schnakenberg. “Simple chemical reaction systems with limit cycle behaviour”. Em: *Journal of Theoretical Biology* 81.3 (1979), pp. 389–400.
- [6] A. M. Turing. “The chemical basis of morphogenesis”. Em: *Philosophical Transactions of the Royal Society of London. Series B, Biological Sciences* 237.641 (1952), pp. 37–72.
- [7] S. Wang, S. Sankaran e P. Perdikaris. “Respecting causality is all you need for training physics-informed neural networks”. Em: *Computer Methods in Applied Mechanics and Engineering* 421 (2024), p. 116813.