

Redes Neurais Informadas por Física (PINNs) versus Métodos de Diferenças Finitas (ADI) na Solução da Equação do Calor 2D em Domínios Irregulares

Autoria omitida para avaliação duplo-cega

Campus da Universidade Federal do Ceará em Quixadá

Resumo

Este trabalho analisa e compara o desempenho do método clássico de Diferenças Finitas com Direções Alternadas Implícitas (ADI de Peaceman-Rachford) e das Redes Neurais Informadas por Física (PINNs) na resolução da equação do calor bidimensional transiente em geometrias complexas. O esquema ADI é consagrado por sua alta eficiência computacional e estabilidade incondicional em malhas cartesianas regulares, operando com custo linear $\mathcal{O}(N)$ por passo de tempo via algoritmo de Thomas. Todavia, em domínios irregulares com múltiplos orifícios circulares internos, a formulação por diferenças finitas sofre com a quebra da estrutura tridiagonal e erros de escadamento nas fronteiras curvas. Em contrapartida, as PINNs superam essas restrições por meio de amostragem livre de malha e diferenciação automática exata sobre o domínio contínuo. Implementou-se um arcabouço em PyTorch para simular a difusão térmica em uma chapa quadrada com três furos circulares mantidos a temperatura nula e bordas externas aquecidas. Os resultados numéricos comprovam que a PINN captura com alta fidelidade o campo transiente e a conformação isotérmica em torno dos furos sem necessidade de geração de malhas adaptativas, evidenciando as vantagens e trade-offs entre métodos numéricos clássicos e aprendizado de máquina científico.

Palavras-chave: Equação do calor; Diferenças Finitas; Método ADI; PINNs; Domínios Irregulares.

ODS: indústria, inovação e infraestrutura.

Abstract

This work investigates and compares the performance of the classical Finite Difference Alternating Direction Implicit method (Peaceman-Rachford ADI) and Physics-Informed Neural Networks (PINNs) for solving the transient 2D heat equation in complex geometries. The ADI scheme is well known for its high efficiency and unconditional stability on regular Cartesian grids ($\mathcal{O}(N)$ cost via Thomas algorithm). However, in irregular domains containing internal circular holes, structured finite differences face tridiagonal matrix breakdown and boundary staircasing errors. In contrast, PINNs eliminate mesh generation by using continuous spatial sampling and exact automatic differentiation. A PyTorch framework was developed to simulate heat conduction on a square plate with three internal circular cooling sinks ($u = 0$) and heated external walls ($u = 1$). Numerical results demonstrate that PINNs accurately capture the transient temperature field and isothermal profiles around curved obstacles without remeshing, highlighting key trade-offs between classical solvers and scientific machine learning.

Keywords: Heat equation; Finite Differences; ADI Method; PINNs; Irregular Domains.

SDG: industry, innovation and infrastructure.

1 Introdução

A modelagem matemática da condução térmica transiente em meios sólidos contínuos desempenha papel central em diversas áreas da engenharia mecânica e da física aplicada, como na dissipação de calor em componentes microeletrônicos, controle de reatores térmicos e otimização de trocadores de calor industriais. Sob as hipóteses de meio homogêneo, isotrópico e com propriedades termofísicas invariantes no tempo e no espaço, a evolução da distribuição de temperatura $u(\mathbf{x}, t)$ é governada pela equação diferencial parcial (EDP) parabólica da difusão:

$$\frac{\partial u}{\partial t} = \alpha \nabla^2 u = \alpha \left(\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} \right) \quad \text{em } \Omega \times (0, T], \quad (1)$$

sujeita à condição inicial $u(\mathbf{x}, 0) = u_0(\mathbf{x})$ e a condições de contorno (Dirichlet ou Neumann) na fronteira $\partial\Omega$, onde $\alpha > 0$ representa o coeficiente de difusividade térmica do material condutor.

Classicamente, a resolução numérica da equação (1) em duas dimensões espaciais baseia-se em métodos de Diferenças Finitas (FDM). Entre as estratégias implícitas mais eficientes destaca-se o método de Direções Alternadas Implícitas (ADI), proposto pioneiramente por Peaceman e Rachford (1955) e extensamente fundamentado na literatura de métodos numéricos para difusão e reação (PEREIRA, 2019). O método ADI fraciona o operador laplaciano bidimensional em dois subpassos unidimensionais intermediários, alcançando precisão de segunda ordem tanto no espaço quanto no tempo ($\mathcal{O}(\Delta t^2 + h^2)$), estabilidade incondicional e custo computacional estritamente linear $\mathcal{O}(N)$ por passo de tempo por meio da resolução de matrizes tridiagonais desacopladas via algoritmo de Thomas (PEREIRA, 2019).

Contudo, a formulação clássica do método ADI encontra uma barreira estrutural severa ao ser aplicada a **domínios geometricamente complexos ou perfurados** (como placas com orifícios de refrigeração ou geometrias curvilíneas). A presença de fronteiras curvas internas interrompe as linhas de grade cartesianas, quebrando a estrutura tensorial das matrizes tridiagonais e exigindo esquemas intrincados de células de corte (*cut-cells*) ou nós fantasmas (*ghost cells*), sob pena de erros de aproximação por escadamento (*staircasing*) que degradam a taxa de convergência espacial (PEREIRA, 2019).

Nesse cenário, as Redes Neurais Informadas por Física (*Physics-Informed Neural Networks* – PINNs), propostas por Raissi et al. (2019) e consolidadas em Karniadakis et al. (2021), surgiram como uma alternativa moderna e totalmente **livre de malha** (*mesh-free*). Em vez de discretizar o meio em uma grade rígida, uma PINN aproxima a solução contínua $u(\mathbf{x}, t)$ por uma rede neural profunda (MLP), cujos pesos são treinados para minimizar simultaneamente o resíduo da EDP e as condições de contorno via diferenciação automática exata baseada no grafo computacional (*Autograd*).

Este artigo tem como objetivo comparar teórica e numericamente o método ADI clássico e as PINNs na resolução da equação do calor 2D transiente em um domínio irregular complexo formado por uma chapa quadrada com três orifícios circulares internos de resfriamento, investigando os trade-offs fundamentais entre custo de treinamento, flexibilidade geométrica e precisão da solução.

2 Desenvolvimento e Metodologia

2.1 Geometria do Domínio e Formulação do Problema

Considera-se o domínio espacial bidimensional perfurado $\Omega \subset \mathbb{R}^2$ constituído pelo quadrado unitário $[0, 1] \times [0, 1]$ subtraído de três orifícios circulares disjuntos $\mathcal{H}_1, \mathcal{H}_2, \mathcal{H}_3$:

$$\Omega = [0, 1]^2 \setminus \bigcup_{k=1}^3 \mathcal{H}_k, \quad \text{com} \quad \mathcal{H}_k = \{(x, y) \in \mathbb{R}^2 \mid (x - x_k)^2 + (y - y_k)^2 \leq r_k^2\}. \quad (2)$$

Os centros e raios dos três furos de resfriamento são parametrizados por:

$$\begin{aligned} (x_1, y_1) &= (0,30; 0,30), \quad r_1 = 0,12; & (x_2, y_2) &= (0,70; 0,30), \quad r_2 = 0,12; \\ (x_3, y_3) &= (0,50; 0,70), \quad r_3 = 0,12. \end{aligned} \quad (3)$$

Adota-se difusividade térmica $\alpha = 0,01$ e horizonte temporal $t \in [0, T_{\max}]$ com $T_{\max} = 1,0$. O sistema inicia-se em repouso térmico isotérmico a temperatura nula:

$$u(x, y, 0) = 0, \quad \forall (x, y) \in \Omega. \quad (4)$$

As condições de contorno de Dirichlet são prescritas de forma diferenciada entre as bordas externas e internas:

- **Fronteira externa** ($\Gamma_{\text{ext}} = \partial[0, 1]^2$): fonte contínua de calor mantida a temperatura unitária, $u(x, y, t)|_{\Gamma_{\text{ext}}} = 1,0$;
- **Fronteiras internas dos furos** ($\Gamma_{\text{int}} = \bigcup_{k=1}^3 \partial\mathcal{H}_k$): sumidouros térmicos mantidos resfriados a $u(x, y, t)|_{\Gamma_{\text{int}}} = 0,0$.

2.2 O Método ADI de Peaceman-Rachford e o Desafio de Geometrias Irregulares

De acordo com o desenvolvimento apresentado em Pereira (2019), decompõe-se o operador diferencial espacial linear $\mathcal{A} = \alpha \nabla^2 = \mathcal{A}_x + \mathcal{A}_y$, em que $\mathcal{A}_x = \alpha \frac{\partial^2}{\partial x^2}$ e $\mathcal{A}_y = \alpha \frac{\partial^2}{\partial y^2}$. O esquema de Peaceman e

Rachford (1955) avança do instante de tempo t^n para t^{n+1} em duas etapas fracionadas de tamanho $\Delta t/2$:

$$\left(\mathcal{I} - \frac{\Delta t}{2}\mathcal{A}_x\right)u^{n+1/2} = \left(\mathcal{I} + \frac{\Delta t}{2}\mathcal{A}_y\right)u^n, \quad (5)$$

$$\left(\mathcal{I} - \frac{\Delta t}{2}\mathcal{A}_y\right)u^{n+1} = \left(\mathcal{I} + \frac{\Delta t}{2}\mathcal{A}_x\right)u^{n+1/2}. \quad (6)$$

Em uma malha cartesiana regular com nós uniformes (x_i, y_j) e espaçamento $h = \Delta x = \Delta y$, as aproximações das derivadas espaciais por diferenças centradas de segunda ordem produzem operadores discretos tridiagonais:

$$\mathcal{A}_x u_{i,j} = \alpha \frac{u_{i+1,j} - 2u_{i,j} + u_{i-1,j}}{h^2}, \quad \mathcal{A}_y u_{i,j} = \alpha \frac{u_{i,j+1} - 2u_{i,j} + u_{i,j-1}}{h^2}. \quad (7)$$

Em geometrias retangulares sem obstruções, a etapa (5) envolve a resolução desacoplada de N_y sistemas lineares tridiagonais de ordem N_x , enquanto a etapa (6) resolve N_x sistemas tridiagonais de ordem N_y . Ambas as etapas são executadas de forma direta pelo algoritmo de Thomas com complexidade estritamente linear $\mathcal{O}(N_x N_y)$ (PEREIRA, 2019).

Obstrução computacional em domínios perfurados: No domínio irregular Ω , a presença dos três furos circulares $\mathcal{H}_k$ introduz limitações severas ao esquema ADI clássico:

1. **Fragmentação das linhas tridiagonais:** As linhas horizontais e verticais de varredura que interceptam os furos são partidas em múltiplos segmentos independentes com nós de contorno internos não alinhados à malha regular, quebrando a estrutura de produto tensorial global;
2. **Erro de fronteira curvilínea:** A representação de bordas circulares sobre uma grade cartesiana induz erros de escadamento (*staircasing*). Métodos compensatórios (como fórmulas assimétricas de Shortley-Weller ou nós fantasmas) aumentam a complexidade algébrica e reduzem a consistência espacial nas bordas para $\mathcal{O}(h)$;
3. **Alternativas não estruturadas:** A migração para o Método de Elementos Finitos (FEM) resolve geometrias curvas via malhas não estruturadas triangulares, porém perde a resolução tridiagonal $\mathcal{O}(N)$ do ADI, exigindo a resolução de sistemas lineares esparsos globais $\mathcal{O}(N^{1.5})$.

2.3 Formulação com Redes Neurais Informadas por Física (PINNs)

A formulação PINN (RAISSI et al., 2019) aproxima o campo contínuo de temperatura por uma rede neural profunda $u_\theta(t, x, y) : \mathbb{R}^3 \rightarrow \mathbb{R}$, parametrizada pelo vetor de pesos e vieses θ . A arquitetura utilizada consiste em um perceptron multicamadas com 4 camadas ocultas, contendo 64 neurônios por camada e função de ativação tangente hiperbólica ($\tanh$), garantindo diferenciabilidade contínua de ordem superior.

A física do problema e as condições de contorno e inicial são impostas diretamente na função de perda total multiobjetivo $\mathcal{L}(\theta)$:

$$\mathcal{L}(\theta) = \mathcal{L}_{\text{pde}} + \mathcal{L}_{\text{ic}} + \mathcal{L}_{\text{bc}}^{\text{ext}} + \mathcal{L}_{\text{bc}}^{\text{furos}}, \quad (8)$$

onde cada termo penaliza o erro quadrático médio em pontos de colocação contínuos:

$$\mathcal{L}_{\text{pde}} = \frac{1}{N_f} \sum_{i=1}^{N_f} \left| \frac{\partial u_\theta}{\partial t}(t_f^i, x_f^i, y_f^i) - \alpha \left(\frac{\partial^2 u_\theta}{\partial x^2}(t_f^i, x_f^i, y_f^i) + \frac{\partial^2 u_\theta}{\partial y^2}(t_f^i, x_f^i, y_f^i) \right) \right|^2, \quad (9)$$

$$\mathcal{L}_{\text{ic}} = \frac{1}{N_{\text{ic}}} \sum_{i=1}^{N_{\text{ic}}} |u_\theta(0, x_{\text{ic}}^i, y_{\text{ic}}^i) - 0|^2, \quad (10)$$

$$\mathcal{L}_{\text{bc}}^{\text{ext}} = \frac{1}{N_b} \sum_{i=1}^{N_b} |u_\theta(t_b^i, \mathbf{x}_{\text{ext}}^i) - 1, 0|^2, \quad (11)$$

$$\mathcal{L}_{\text{bc}}^{\text{furos}} = \sum_{k=1}^3 \frac{1}{N_h} \sum_{j=1}^{N_h} |u_\theta(t_h^j, x_k + r_k \cos \theta_j, y_k + r_k \sin \theta_j) - 0, 0|^2. \quad (12)$$

Amostragem Geométrica sem Malha: Os N_f pontos de colocação internos são gerados por amostragem aleatória uniforme sobre $[0, 1]^2$ com filtro de rejeição booleano para os três círculos:

$$(x_f - x_k)^2 + (y_f - y_k)^2 > r_k^2, \quad \forall k \in \{1, 2, 3\}. \quad (13)$$

Os pontos nas fronteiras dos furos são parametrizados de forma exata e contínua pelo ângulo polar $\theta \sim \mathcal{U}[0, 2\pi)$, dispensando discretização poligonal. As derivadas parciais espaciais de segunda ordem e temporais são calculadas analiticamente via diferenciação automática exata do PyTorch (*Autograd*).

3 Resultados e Discussão

O treinamento da PINN foi realizado durante 10.000 épocas utilizando o otimizador estocástico Adam com taxa de aprendizado $\eta = 10^{-3}$, empregando $N_f = 20.000$ pontos de colocação no domínio espaço-temporal $\Omega \times [0, 1]$, $N_{ic} = 5.000$ pontos na condição inicial, $N_b = 4.000$ pontos nas quatro fronteiras externas e $N_h = 10.000$ pontos distribuídos nos contornos circulares dos três furos.




Figura 1: Campos de temperatura $u(x, y, t)$ calculados pela PINN no domínio perfurado com três sumidouros térmicos circulares internos mantidos a $u = 0$ e bordas externas a $u = 1$.

A Figura 1(a) exibe o perfil térmico predito pela PINN no instante $t = 0,80$. Observa-se a propagação gradual da frente de calor advinda das quatro paredes externas aquecidas ($u = 1,0$) em direção ao centro da chapa, gerando fortes gradientes térmicos nas vizinhanças imediatas dos três orifícios de resfriamento ($u = 0,0$). A rede neural satisfaz com precisão a condição homogênea em toda a circunferência curva dos furos sem apresentar distorções ou oscilações numéricas de Gibbs.

Na Figura 1(b), correspondente a $t = 4,50$, verifica-se a estabilização suave do campo de temperatura em direção ao regime permanente, demonstrando a robustez do método livre de malha na preservação da estabilidade assintótica.

3.1 Comparativo Estrutural: ADI versus PINN

A Tabela 1 apresenta uma síntese comparativa das propriedades operacionais e metodológicas entre o método de diferenças finitas ADI e as PINNs.

Tabela 1: Comparativo metodológico e operacional entre o método ADI e PINNs.

Característica	Método ADI (Diferenças Finitas)	PINN (Rede Neural)
Geração de Malha	Obrigatória (cartesiana estruturada)	Desnecessária (amostragem contínua)
Domínios com Furos	Complexo (quebra tridiagonal / nós fantasmas)	Direto (rejeição booleana de pontos)
Bordas Curvilíneas	Erro de escapeamento ($\mathcal{O}(h)$)	Representação exata via Autograd
Custo por Passo Temporal	$\mathcal{O}(N)$ (Thomas ultrarrápido)	Inferência matricial direta contínua
Custo de Treinamento/Ajuste	Nulo (solução por marcha no tempo)	Elevado (otimização não linear via Adam)
Representação da Solução	Discreta em nós de grade (x_i, y_j, t_n)	Contínua e diferenciável $u_\theta(t, x, y)$
Extensão para Não Linearidades	Requer linearização prévia (PEREIRA, 2019)	Natural via resíduo no grafo computacional

Enquanto o método ADI é insuperável em velocidade de execução pura quando restrito a geometrias retangulares sem descontinuidades devido à resolução tridiagonal direta ($\mathcal{O}(N)$ por passo), as PINNs oferecem flexibilidade geométrica superior em problemas com múltiplos contornos curvilíneos internos. A representação contínua da PINN permite avaliar a qualquer momento campos térmicos pontuais e fluxos de calor normais $-\alpha \frac{\partial u}{\partial \mathbf{n}}$ em qualquer coordenada espacial e temporal sem necessidade de interpolações locais adicionais.

4 Considerações Finais

Este trabalho apresentou um estudo comparativo entre o método clássico de Diferenças Finitas com Direções Alternadas Implícitas (ADI de Peaceman-Rachford) e as Redes Neurais Informadas por Física (PINNs) na solução da equação do calor 2D transiente em domínios irregulares com múltiplos orifícios circulares.

A análise teórica baseada no arcabouço de métodos de diferenças finitas (PEREIRA, 2019) detalhou as obstruções do esquema ADI diante de contornos curvilíneos internos em virtude da fragmentação das matrizes tridiagonais e erros de escadeamento. Em contrapartida, a implementação da PINN em PyTorch demonstrou excelente aderência física, resolvendo a difusão térmica e impondo condições de contorno de Dirichlet sobre geometrias perfuradas sem necessidade de malhas adaptativas ou esquemas de interpolação complexos.

Como trabalhos futuros, planeja-se estender esta comparação para sistemas não lineares de difusão-reação acoplados, avaliando o comportamento de PINNs frente a esquemas de linearização associada ao ADI e esquemas tri-bloco-diagonais em problemas de formação de padrões de Turing e dinâmica de difusão cruzada presa-predador.

Agradecimentos

Agradecimento à Universidade Federal do Ceará (Campus Quixadá) pelo suporte acadêmico e institucional.

Referências

- [1] PEACEMAN, D. W.; RACHFORD, H. H. The numerical solution of parabolic and elliptic differential equations. **Journal of the Society for Industrial and Applied Mathematics**, v. 3, n. 1, p. 28–41, 1955.
- [2] PEREIRA, R. R. **Métodos de Diferenças Finitas para Problemas de Difusão e Reação Não Lineares**. Tese (Doutorado em Modelagem Computacional) – Laboratório Nacional de Computação Científica (LNCC), Petrópolis, RJ, 2019.
- [3] RAISSI, M.; PERDIKARIS, P.; KARNIADAKIS, G. E. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. **Journal of Computational Physics**, v. 378, p. 686–707, 2019.
- [4] KARNIADAKIS, G. E.; KEVREKIDIS, I. G.; LU, L.; PERDIKARIS, P.; WANG, S.; YANG, L. Physics-informed machine learning. **Nature Reviews Physics**, v. 3, n. 6, p. 422–440, 2021.
- [5] STRANG, G.; FIX, G. J. **An analysis of the finite element method**. Englewood Cliffs: Prentice-Hall, 1973.
- [6] LU, L.; MENG, X.; MAO, Z.; KARNIADAKIS, G. E. DeepXDE: A deep learning library for solving differential equations. **SIAM Review**, v. 63, n. 1, p. 208–228, 2021.