

Redes Neurais Informadas por Física (PINNs) para a Resolução Numérica das Equações Bidimensionais do Calor e de Burgers

Autoria omitida para avaliação duplo-cega

Campus da Universidade Federal do Ceará em Quixadá

RESUMO

Este trabalho investiga o paradigma das Redes Neurais Informadas por Física (PINNs) aplicado à solução numérica de dois problemas canônicos regidos por equações diferenciais parciais (EDPs) bidimensionais. No primeiro experimento, trata-se a equação do calor transiente linear ($\alpha = 0,1$) em domínio quadrado com condições de Dirichlet, validando a predição neural contra a solução analítica por separação de variáveis com erro absoluto inferior a 10^{-3} . No segundo, resolve-se a equação vetorial de Burgers viscosa ($\nu = 0,01$) com condição inicial dipolar — dois vórtices gaussianos de sinais opostos — capturando a dinâmica não-linear de colisão e dissipação viscosa sem geração de malha. O arcabouço PINN codifica as restrições físicas (resíduo da EDP, condições de contorno e inicial) diretamente na função de perda multiobjetivo via diferenciação automática, atingindo $\mathcal{L}_{\text{total}} \approx 1,64 \times 10^{-4}$ em Burgers e $1,62 \times 10^{-2}$ no calor ao final do treinamento.

Palavras-chave: redes neurais informadas por física; equação do calor; equação de Burgers; equações diferenciais parciais; aprendizado de máquina científico

ODS: indústria, inovação e infraestrutura

ABSTRACT

This work investigates the Physics-Informed Neural Networks (PINNs) paradigm for the numerical solution of two canonical two-dimensional PDE problems. In the first experiment, we address the linear transient heat equation ($\alpha = 0.1$) on a unit square with Dirichlet boundary conditions, validating the neural solution against the exact analytical Fourier-series result with absolute errors below 10^{-3} . In the second, we solve the viscous vector Burgers equation ($\nu = 0.01$) with a dipolar Gaussian initial condition—two opposite-sign vortices—capturing the nonlinear collision and viscous dissipation dynamics without mesh generation. The PINN framework encodes physical constraints (PDE residual, boundary and initial conditions) directly in a multi-objective loss function via automatic differentiation, reaching $\mathcal{L}_{\text{total}} \approx 1.64 \times 10^{-4}$ for Burgers and 1.62×10^{-2} for the heat equation at the end of training.

Keywords: physics-informed neural networks; heat equation; Burgers equation; partial differential equations; scientific machine learning

SDG: industry, innovation and infrastructure

1 INTRODUÇÃO

A modelagem de fenômenos físicos por equações diferenciais parciais (EDPs) sustenta a engenharia e as ciências aplicadas. Métodos numéricos clássicos — como Diferenças Finitas (MDF) [2], Elementos Finitos (MEF) e Volumes Finitos (MVF) — convertem operadores diferenciais contínuos em sistemas algébricos via discretização de malha estruturada ou não-estruturada. Embora consolidados, esquemas baseados em malha enfrentam desafios de escalabilidade dimensional e custo de geração de malhas em domínios complexos [2], motivando abordagens alternativas livres de malha.

A aproximação de EDPs por redes neurais ganhou impulso definitivo com as *Physics-Informed Neural Networks* (PINNs) propostas por Raissi, Perdikaris e Karniadakis [3]: as restrições físicas (resíduo da equação, condições iniciais e de contorno) são inseridas diretamente na função de perda otimizada, utilizando diferenciação automática para avaliar derivadas parciais sem necessidade de dados rotulados.

Este trabalho investiga o arcabouço PINN aplicado a dois problemas bidimensionais canônicos: (i) a equação do calor transiente (EDP linear parabólica), analisando a propagação contínua da temperatura no espaço 3D (x, y, u) ; e (ii) a equação vetorial de Burgers viscosa (EDP não-linear hiperbólica-parabólica), modelo de referência em mecânica dos fluidos e transporte não-linear [1, 2].

2 DESENVOLVIMENTO

2.1 Fundamentação Teórica

Equação do Calor 2D Transiente. A condução térmica em sólido bidimensional homogêneo e isotrópico com difusividade $\alpha > 0$ é governada por:

$$\frac{\partial u}{\partial t} = \alpha \left(\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} \right), \quad (x, y, t) \in [0, 1]^2 \times (0, 1], \quad (1)$$

com $u|_{\partial\Omega} = 1$ e $u(\cdot, 0) = 0$. A solução exata por separação de variáveis é a série dupla de Fourier: $u^* = 1 - \sum_{m,n \text{ ímp.}} C_{mn} \sin(m\pi x) \sin(n\pi y) e^{-\alpha\pi^2(m^2+n^2)t}$, com $C_{mn} = 16/(\pi^2 mn)$, truncada em $m, n \leq 25$.

Equação de Burgers 2D Viscosa. O campo vetorial de velocidade $\mathbf{u} = (u, v)$ satisfaz o sistema acoplado [1, 2]:

$$\partial_t u + u \partial_x u + v \partial_y u = \nu \nabla^2 u, \quad (2)$$

$$\partial_t v + u \partial_x v + v \partial_y v = \nu \nabla^2 v, \quad (3)$$

com $\nu > 0$, $\Omega = [-1, 1]^2 \times [0, 1]$ e condições de Dirichlet homogêneas nas fronteiras ($\mathbf{u} = \mathbf{0}$). O termo advectivo $(\mathbf{u} \cdot \nabla)\mathbf{u}$ introduz a não-linearidade característica do escoamento de fluidos.

Arquitetura Neural e Operadores Diferenciais via Autograd. A aproximação contínua $\mathbf{u}_\theta \approx \mathbf{u}$ é parametrizada por um perceptron multicamadas (MLP) profundo $f_\theta : \mathbb{R}^3 \rightarrow \mathbb{R}^d$ ($d = 1$ para calor, $d = 2$ para Burgers), com vetor de entrada $\mathbf{z} = (t, x, y)^\top$ e $L = 4$ camadas ocultas de $n = 64$ neurônios:

$$\mathbf{h}^{(0)} = \mathbf{z}, \quad \mathbf{h}^{(\ell)} = \sigma(\mathbf{W}^{(\ell)} \mathbf{h}^{(\ell-1)} + \mathbf{b}^{(\ell)}), \quad \ell = 1, \dots, L, \quad \mathbf{u}_\theta(\mathbf{z}) = \mathbf{W}^{(L+1)} \mathbf{h}^{(L)} + \mathbf{b}^{(L+1)}, \quad (4)$$

com ativação suave $\sigma(s) = \tanh(s) \in C^\infty(\mathbb{R})$ para garantir a existência de derivadas espaciais e temporais contínuas de ordem arbitrária. As derivadas parciais requeridas pelas equações são calculadas de forma exata pelo grafo computacional via diferenciação automática em modo reverso (*Autograd*):

$$\frac{\partial \mathbf{u}_\theta}{\partial x_j} = \nabla_{\mathbf{z}} \mathbf{u}_\theta \cdot \mathbf{e}_j, \quad \frac{\partial^2 \mathbf{u}_\theta}{\partial x_j^2} = \nabla_{\mathbf{z}} \left(\frac{\partial \mathbf{u}_\theta}{\partial x_j} \right) \cdot \mathbf{e}_j, \quad j \in \{1, 2, 3\}. \quad (5)$$

Otimização Multiobjetivo. O treinamento formula-se como a minimização irrestrita sobre os parâmetros θ com otimizador Adam ($\eta = 10^{-3}$) sob a função de perda:


$$\mathcal{L}(\theta) = \mathcal{L}_{\text{pde}}(\theta) + \lambda_{\text{ic}} \mathcal{L}_{\text{ic}}(\theta) + \lambda_{\text{bc}} \mathcal{L}_{\text{bc}}(\theta), \quad (6)$$

$$\mathcal{L}_{\text{pde}} = \frac{1}{N_f} \sum_{i=1}^{N_f} \|\mathcal{F}[\mathbf{u}_\theta](\mathbf{z}_i^f)\|_2^2, \quad \mathcal{L}_{\text{ic}} = \frac{1}{N_0} \sum_{i=1}^{N_0} \|\mathbf{u}_\theta(\mathbf{x}_i^0, 0) - \mathbf{u}_0(\mathbf{x}_i^0)\|_2^2, \quad \mathcal{L}_{\text{bc}} = \frac{1}{N_b} \sum_{i=1}^{N_b} \|\mathbf{u}_\theta(\mathbf{x}_i^b, t_i^b) - \mathbf{g}(\mathbf{x}_i^b, t_i^b)\|_2^2, \quad (7)$$

onde $\mathcal{F}[\mathbf{u}_\theta]$ denota o resíduo diferencial da EDP e $\lambda_{\text{ic}} = \lambda_{\text{bc}} = 1, 0$. A Figura 1 ilustra o fluxo computacional da rede.

Figura 1 — Arquitetura PINN: MLP 4×64 com ativação tanh e função de perda multiobjetivo (6) computada via *Autograd*.

Arquitetura da PINN: MLP 4×64 com ativação tanh e função de perda multiobjetivo



Fonte: Elaboração própria (versão identificada).

2.2 Metodologia

A Tabela 1 resume os parâmetros adotados. Os N_f pontos de colocação de domínio foram amostrados uniformemente em $\Omega \times [0, 1]$; os N_b pontos de fronteira, sobre $\partial\Omega \times [0, 1]$.

Tabela 1 — Configuração experimental — Equações do Calor e de Burgers 2D.

Hiperparâmetro	Calor 2D	Burgers 2D
Arquitetura	MLP 4×64 , tanh	MLP 4×64 , tanh
Entrada / Saída	$(t, x, y) \rightarrow u$	$(t, x, y) \rightarrow (u, v)$
Otimizador	Adam, $\eta = 10^{-3}$	Adam, $\eta = 10^{-3}$
Épocas	8 000	10 000
$N_f / N_0 / N_b$	$10^4 / 10^4 / 4k$	$10^4 / 10^4 / 4k$
Parâmetro físico	$\alpha = 0,1$	$\nu = 0,01$
Domínio	$[0, 1]^2$, Dirichlet $u = 1$	$[-1, 1]^2$, Dirichlet $u = 0$

Fonte: Elaboração própria (versão identificada).

Para a equação de Burgers 2D, a condição inicial dipolar é:

$$u_0(x, y) = e^{-20[(x+0,4)^2+y^2]} - e^{-20[(x-0,4)^2+y^2]}, \quad v_0 = 0, \quad (8)$$

composta por dois vórtices gaussianos de sinais opostos centrados em $(\pm 0,4, 0)$, gerando gradientes abruptos que desafiam esquemas numéricos.

2.3 Resultados e Discussão

Convergência das Perdas. A Figura 2 apresenta as curvas de convergência em escala semilogarítmica. No calor (operador linear), a perda de contorno $\mathcal{L}_{bc}$ atinge rápida estabilização, totalizando $\mathcal{L}_{total} \approx 1,62 \times 10^{-2}$ em 8 000 épocas. Em Burgers (sistema não-linear acoplado), a perda atinge $1,64 \times 10^{-4}$ em 10 000 épocas com $\mathcal{L}_{bc} \approx 4 \times 10^{-6}$, garantindo satisfação rigorosa das condições de Dirichlet.

Experimento 1 — Evolução Térmica 3D (Calor 2D). A Figura 3 ilustra a evolução da superfície $u_\theta(x, y, t)$ predita pela rede em quatro instantes temporais. Em $t = 0$, o perfil reflete a condição inicial homogênea ($u = 0$) com elevação nas bordas ($u = 1$). À medida que o tempo avança ($t = 0,3 \rightarrow 0,7 \rightarrow 1,0$), a difusão térmica penetra suavemente em direção ao núcleo do domínio quadrado, atingindo campo quase estacionário em $t = 1,0$, com erro absoluto pontual frente à solução analítica por Fourier inferior a 10^{-3} na maior parte do domínio.

Experimento 2 — Dinâmica do Dipolo e Campo de Velocidade (Burgers 2D). A Figura 4 sintetiza a dinâmica não-linear de Burgers. Nos painéis 3D (a,b), o dipolo gaussiano inicial em $t = 0$

Figura 2 — Convergência semilogarítmica de $\mathcal{L}$ (6): (a) Calor 2D, 8 000 épocas; (b) Burgers 2D, 10 000 épocas.





Figura 3 — Equação do Calor 2D — evolução da distribuição de temperatura em superfície 3D $u_\theta(x,y,t)$ predita pela PINN para $t \in \{0,0; 0,3; 0,7; 1,0\}$.


Equação do Calor 2D: evolução da distribuição térmica $u_\theta(x,y,t)$ predita pela PINN ($\alpha = 0,1$)



exibe picos simétricos $u \approx \pm 1$; em $t = 0,5$, a ação combinada da advecção e da difusão viscosa ($\nu = 0,01$) atenua as cristas para $|u| \approx 0,6$ e desloca as estruturas no plano. Os painéis de magnitude da velocidade (c–e) $\|\mathbf{u}\| = \sqrt{u^2 + v^2}$ revelam a expansão e o amortecimento gradual do escoamento, dissipando a energia cinética de pico até $t = 1,0$.

Figura 4 — Eq. de Burgers 2D — dissipação viscosa do dipolo: (a,b) superfícies 3D $u_\theta(x,y,t)$ em $t = 0$ e $t = 0,5$; (c–e) magnitude do campo de velocidade $\|\mathbf{u}(x,y,t)\|$ em $t = 0,0$, $t = 0,5$ e $t = 1,0$.

Eq. de Burgers 2D: dissipação do dipolo — (a,b) superfícies u_θ e (c–e) magnitude da velocidade $\|\mathbf{u}\|$



Análise Comparativa. A Tabela 2 sumariza os resultados quantitativos. A menor perda em Burgers

reflete a conformidade das condições homogêneas de contorno. Diferentemente dos esquemas tradicionais de diferenças finitas [2], que demandam malhas e passos de discretização espaçotemporais ($\Delta x, \Delta t$) sujeitos a restrições de estabilidade (CFL), a PINN fornece um interpolador contínuo diferenciável que pode ser avaliado instantaneamente em qualquer ponto (x, y, t) .

Tabela 2 — Indicadores quantitativos ao término do treinamento.

Indicador	Calor 2D	Burgers 2D
Épocas	8 000	10 000
$\mathcal{L}_{\text{total}}$	$1,62 \times 10^{-2}$	$1,64 \times 10^{-4}$
$\mathcal{L}_{\text{pde}}$	$2,45 \times 10^{-3}$	$1,09 \times 10^{-4}$
$\mathcal{L}_{\text{bc}}$	$8,54 \times 10^{-3}$	$4,26 \times 10^{-6}$
$\mathcal{L}_{\text{ic}}$	$5,25 \times 10^{-3}$	$5,06 \times 10^{-5}$
Erro abs. vs. referência	$< 2 \times 10^{-2}$	—
C.C. (tipo / valor)	Dirichlet, $u = 1$	Dirichlet, $u = v = 0$

Fonte: Elaboração própria (versão identificada).

3 CONSIDERAÇÕES FINAIS

Os experimentos confirmam que as PINNs são capazes de resolver EDPs lineares (Calor 2D) e não-lineares acopladas (Burgers 2D) com fidelidade física, representação contínua e sem necessidade de malha espacial. Como trabalhos futuros, pretende-se estender a metodologia para sistemas de Navier-Stokes incompressíveis e problemas inversos de estimação de parâmetros físicos a partir de dados experimentais esparsos.

REFERÊNCIAS

- [1] J. M. Burgers. “A mathematical model illustrating the theory of turbulence”. Em: *Advances in Applied Mechanics* 1 (1948), pp. 171–199.
- [2] R. R. Pereira. “Métodos de Diferenças Finitas para Problemas de Difusão e Reação Não Lineares”. Tese de dout. Petrópolis, RJ: Laboratório Nacional de Computação Científica (LNCC), 2019.
- [3] M. Raissi, P. Perdikaris e G. E. Karniadakis. “Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations”. Em: *Journal of Computational Physics* 378 (2019), pp. 686–707.