

O PAPEL DA CAUSALIDADE TEMPORAL E DA RIGIDEZ NUMÉRICA NA FALHA DE PINNS PARA PADRÕES DE TURING: UMA ANÁLISE CRÍTICA DO MODELO DE SCHNAKENBERG

Autor Principal*

Orientador**

RESUMO

Este trabalho investiga as causas fundamentais pelas quais as Redes Neurais Informadas por Física (PINNs) em formulação padrão contínua falham na simulação direta (*forward*) de padrões de Turing no modelo de reação-difusão de Schnakenberg. Com base nos parâmetros exatos da tese de Pereira (2019) ($D_v/D_u = 20$, $\kappa = 100$ no domínio unitário $\Omega = [0, 1]^2$), conduziram-se experimentos com um Perceptron Multicamadas (MLP) de 5 camadas ocultas (66.818 parâmetros) treinado por 20.000 épocas via otimizador Adam na GPU. Demonstra-se o paradoxo da convergência espúria: a despeito de atingir perda residual global reduzida ($\mathcal{L}_{\text{total}} = 1,95 \times 10^{-4}$) e resíduo inicial quase nulo ($\mathcal{L}_{\text{ic}} = 4,02 \times 10^{-8}$), a rede colapsa integralmente para o estado estacionário homogêneo trivial ($u^* = 0,90$), incorrendo em um erro relativo L_2 de 60,85% em relação à referência. Identificam-se três patologias estruturais: (i) a quebra da causalidade temporal pela amostragem global em $\Omega \times [0, T]$, onde a retropropagação (*backpropagation*) de resíduos futuros suprime perturbações pretéritas; (ii) a rigidez cinética reativa; e (iii) o viés espectral da MLP contra modos de alta frequência. Em contrapartida, revisita-se o Método de Diferenças Finitas (MDF) com Direções Alternadas Implícitas (ADI) linearizado de Pereira (2019), cuja marcha temporal causal estrita assegura estabilidade incondicional $\mathcal{O}(\Delta t^2)$ e resolução exata das manchas periódicas (*spots*) em 9,59 s.

Palavras-chave: redes neurais informadas por física; causalidade temporal; instabilidade de turing; modelo de schnakenberg; rigidez numérica; método de diferenças finitas; direções alternadas implícitas

ODS: indústria, inovação e infraestrutura

ABSTRACT

This work investigates the fundamental causes behind the failure of standard continuous Physics-Informed Neural Networks (PINNs) in forward simulations of Turing patterns in the Schnakenberg reaction-diffusion model. Based on the exact benchmark parameters from the thesis of Pereira (2019) ($D_v/D_u = 20$, $\kappa = 100$ on the unit domain $\Omega = [0, 1]^2$), experiments were carried out using a deep Multi-Layer Perceptron (MLP) with 5 hidden layers (66,818 trainable parameters) trained for 20,000 epochs with Adam on GPU. We demonstrate the spurious convergence paradox: despite reaching a very low global residual loss ($\mathcal{L}_{\text{total}} = 1.95 \times 10^{-4}$) and negligible initial condition residual ($\mathcal{L}_{\text{ic}} = 4.02 \times 10^{-8}$), the network collapses into the trivial homogeneous steady state ($u^* = 0.90$), yielding a relative L_2 error of 60.85% against the reference solution. Three structural pathologies are identified: (i) violation of temporal causality via global space-time collocation, where error backpropagation from future states suppresses past perturbations; (ii) kinetic stiffness; and (iii) spectral bias against critical wavenumbers. In contrast, we revisit the Finite Difference Method (FDM) with Linearized Alternating Direction Implicit (ADI) time-stepping from Pereira (2019), whose strictly causal marching guarantees unconditional $\mathcal{O}(\Delta t^2)$ stability and exact periodic spot formation in 9.59 s.

*autor@alu.ufc.br

**orientador@ufc.br

Keywords: physics-informed neural networks; temporal causality; turing instability; schnakenberg model; numerical stiffness; finite difference method; alternating direction implicit

SDG: industry, innovation and infrastructure

1 INTRODUÇÃO

A emergência espontânea de estruturas periódicas e quebras de simetria em sistemas de reação-difusão, concebida por Alan Turing em seu trabalho seminal (Turing, 1952), fundamenta a compreensão da morfogênese biológica e dos processos de auto-organização não linear (Murray, 2003). No modelo canônico de Schnakenberg (Schnakenberg, 1979), cinéticas reativas trimoleculares acopladas a taxas de difusão desiguais ($D_v \gg D_u$) amplificam perturbações imperceptíveis na escala inicial ($\sim 10^{-3}$), reorganizando o meio homogêneo em redes periódicas de manchas (*spots*).

Com os avanços do aprendizado científico de máquina, as Redes Neurais Informadas por Física (PINNs) (Raissi; Perdikaris; Karniadakis, 2019) consolidaram-se como um paradigma contínuo e livre de malha (*meshless*). Ao embutir os operadores diferenciais da Equação Diferencial Parcial (EDP) no funcional de perda via diferenciação automática (*autograd*), as PINNs aproximam soluções no espaço-tempo global. Todavia, a formulação padrão de PINNs enfrenta graves entraves diante de **sistemas regidos por instabilidades dinâmicas e bifurcações espaciais**.

Em simulações diretas (*forward*) de padrões de Turing, constata-se um paradoxo empírico: a rede atinge resíduos globais diminutos ($\mathcal{L} < 10^{-3}$), mas o campo predito permanece estagnado no equilíbrio homogêneo trivial, suprimindo os padrões morfogênicos. Este artigo analisa os mecanismos físico-matemáticos desse colapso no modelo de Schnakenberg, adotando como base a formulação de Pereira (2019). Demonstra-se como a **quebra da causalidade temporal**, a **rigidez reativa** ($\kappa = 100$) e o **viés espectral** aprisionam a rede no estado plano. Em paralelo, comprova-se a superioridade da marcha causal sequencial do **Método de Diferenças Finitas (MDF)** com **Direções Alternadas Implícitas (ADI)** linearizado (Pereira, 2019).

2 DESENVOLVIMENTO

2.1 Fundamentação Teórica

Modelo de Reação-Difusão de Schnakenberg: No domínio unitário bidimensional $\Omega = [0, 1]^2 \text{ m}^2$ sob contornos de fluxo nulo $\nabla u \cdot \mathbf{n} = \nabla v \cdot \mathbf{n} = 0$ em $\partial\Omega$, o modelo é regido pelo par acoplado (Schnakenberg, 1979; Pereira, 2019):

$$\frac{\partial u}{\partial t} = D_u \nabla^2 u + \kappa (a - u + u^2 v), \quad \frac{\partial v}{\partial t} = D_v \nabla^2 v + \kappa (b - u^2 v), \quad (1)$$

onde u, v são concentrações de ativador e inibidor, D_u, D_v os coeficientes difusivos, $a, b > 0$ constantes cinéticas e κ a escala de reação. O equilíbrio homogêneo (u^*, v^*) satisfaz $u^* = a + b$, $v^* = b/(a + b)^2$ (Pereira, 2019).

Pela Análise Linear de Estabilidade (LSA) com perturbações periódicas proporcionais a $e^{\lambda t} \cos(k_x x) \cos(k_y y)$, a matriz Jacobiana da reação em (u^*, v^*) é dada por (Murray, 2003):

$$J = \begin{pmatrix} f_u & f_v \\ g_u & g_v \end{pmatrix} = \begin{pmatrix} \frac{b-a}{a+b} & (a+b)^2 \\ -\frac{2b}{a+b} & -(a+b)^2 \end{pmatrix}. \quad (2)$$

Para a emergência de instabilidade de Turing impulsionada por difusão, quatro condições devem coexistir (Murray, 2003; Pereira, 2019):

$$\text{Tr}(J) < 0, \quad \det(J) > 0, \quad D_v f_u + D_u g_v > 0, \quad (D_v f_u + D_u g_v)^2 > 4 D_u D_v \det(J). \quad (3)$$

Sob essas condições, perturbações no entorno do modo crítico $k_c^2 \approx 135 \text{ rad}^2/\text{m}^2$ sofrem amplificação exponencial $\propto e^{\lambda(k^2)t}$ com $\text{Re}(\lambda) > 0$, quebrando a simetria espacial e gerando os *spots*.

O Esquema MDF ADI Semi-Implicito Linearizado: Para superar a rigidez temporal preservando a causalidade física, Pereira (2019) formulou o método ADI linearizado de Peaceman-Rachford ($n \rightarrow n + 1/2 \rightarrow n + 1$):

$$\left(I - \frac{D_u \Delta t}{2} \delta_x^2\right) u^{n+1/2} = \left(I + \frac{D_u \Delta t}{2} \delta_y^2\right) u^n + \frac{\Delta t}{2} \kappa \tilde{f}^{n+1/2}, \quad (4)$$

$$\left(I - \frac{D_u \Delta t}{2} \delta_y^2\right) u^{n+1} = \left(I + \frac{D_u \Delta t}{2} \delta_x^2\right) u^{n+1/2} + \frac{\Delta t}{2} \kappa \tilde{f}^{n+1/2}, \quad (5)$$

onde $\tilde{f}^{n+1/2}$ é o termo reativo predito linearizado em $t^{n+1/2}$ por Taylor de segunda ordem (Pereira, 2019). Esse esquema desacopla as coordenadas em matrizes tridiagonais $\mathcal{O}(N)$ resolvidas pelo Algoritmo de Thomas, com estabilidade incondicional e ordem $\mathcal{O}(\Delta t^2)$ (Pereira, 2019).

Arquitetura PINN, Autograd e Retropropagação: A PINN parametriza $\hat{\mathbf{w}}_\theta = [\hat{u}_\theta, \hat{v}_\theta]^\top$ via MLP sobre $\mathbf{z} = [x, y, t]^\top \in \Omega \times [0, T]$ em $L = 5$ camadas ocultas com largura $d_h = 128$ ($N_\theta = 66.818$ pesos) e ativação $\sigma(z) = \tanh(z) \in C^\infty(\mathbb{R})$:

$$\mathbf{h}_1 = \sigma(\mathbf{W}_1 \mathbf{z} + \mathbf{b}_1), \quad \mathbf{h}_\ell = \sigma(\mathbf{W}_\ell \mathbf{h}_{\ell-1} + \mathbf{b}_\ell) \quad (\ell = 2, \dots, L), \quad \hat{\mathbf{w}}_\theta(\mathbf{z}) = \mathbf{W}_{L+1} \mathbf{h}_L + \mathbf{b}_{L+1}. \quad (6)$$

O treinamento combina dois fluxos: (i) a **diferenciação automática (autograd)** em relação a $\mathbf{z}$ para obter derivadas parciais da EDP ($\frac{\partial \hat{u}}{\partial t}, \nabla^2 \hat{u}, \frac{\partial \hat{v}}{\partial t}, \nabla^2 \hat{v}$) sem malha (Raissi; Perdikaris; Karniadakis, 2019); e (ii) a **retropropagação (backpropagation)** de $\mathcal{L}(\theta)$ para atualizar os parâmetros θ via otimizador estocástico. O funcional multiobjetivo L_2 é expresso por:

$$\begin{aligned} \mathcal{L}(\theta) = & \frac{1}{N_f} \sum_{i=1}^{N_f} \left(\|\mathcal{R}_u^{(i)}\|^2 + \|\mathcal{R}_v^{(i)}\|^2 \right) + \frac{\lambda_{ic}}{N_0} \sum_{j=1}^{N_0} \|\hat{\mathbf{w}}_0^{(j)} - \mathbf{w}_0^{(j)}\|^2 \\ & + \frac{\lambda_{bc}}{N_b} \sum_{k=1}^{N_b} \left(\|\nabla \hat{u}^{(k)} \cdot \mathbf{n}\|^2 + \|\nabla \hat{v}^{(k)} \cdot \mathbf{n}\|^2 \right), \end{aligned} \quad (7)$$

onde $\mathcal{R}_u = \frac{\partial \hat{u}}{\partial t} - D_u \nabla^2 \hat{u} - \kappa(a - \hat{u} + \hat{u}^2 \hat{v})$ e $\mathcal{R}_v = \frac{\partial \hat{v}}{\partial t} - D_v \nabla^2 \hat{v} - \kappa(b - \hat{u}^2 \hat{v})$.

2.2 Metodologia

Adotaram-se os parâmetros canônicos formalizados na tese de Pereira (2019, Cap. 2 e 4), sintetizados na Tabela 1. O domínio espacial corresponde a $\Omega = [0, 1]^2$ e o horizonte temporal a $t \in [0, 2,0 \text{ s}]$.

Tabela 1 — Parâmetros físicos, dimensionais e hiperparâmetros de rede adotados conforme Pereira (2019).

Parâmetro	Descrição Física / Numérica	Valor Adotado
Ω, T	Domínio espacial e horizonte temporal	$[0, 1]^2 \text{ m}^2, \quad T = 2,0 \text{ s}$
a, b, κ	Parâmetros cinéticos da reação	$a = 0,1305, \quad b = 0,7695, \quad \kappa = 100,0$
D_u, D_v	Coefficientes de difusão ($D_v/D_u = 20$)	$D_u = 0,05, \quad D_v = 1,00$
(u^*, v^*)	Equilíbrio estacionário homogêneo	$(0,9000, 0,9500)$
N_f, N_0, N_b	Pontos de colocação (EDP, IC e BC Neumann)	10.000, 2.500, 2.000
Arquitetura	Camadas ocultas e neurônios	5×128 neurônios (66.818 pesos)
MLP		
Otimizador	Adam com Cosine Annealing	20.000 épocas (19,5 min GPU)

Fonte: Elaboração própria com base em Pereira (2019).

A condição inicial é uma perturbação gaussiana de amplitude $\epsilon = 10^{-3}$ centrada em $(1/3, 1/2)$ (Pereira, 2019):


$$u(x, y, 0) = u^* + 10^{-3} e^{-100[(x-1/3)^2 + (y-1/2)^2]}, \quad v(x, y, 0) = v^*. \quad (8)$$

O treinamento foi executado por 20.000 épocas em GPU (NVIDIA RTX 3050, tempo total de 19,49 min). A solução numérica de referência foi gerada pelo resolvidor MDF ADI linearizado de Pereira (2019) em malha de 128×128 nós com $\Delta t = 10^{-3} \text{ s}$.

2.3 Resultados e Discussão

O Paradoxo da Convergência Espúria e Heterogeneidade Temporal: A Figura 1(a) ilustra a convergência das perdas ao longo das 20.000 épocas. A perda total atinge $\mathcal{L}_{\text{total}} = 1,95 \times 10^{-4}$, com $\mathcal{L}_{\text{ic}} = 4,02 \times 10^{-8}$. Contudo, a amplitude de heterogeneidade $\|u(t) - u^*\|_{L_2}$ (Figura 1(b)) comprova o colapso: enquanto o MDF ADI exhibe amplificação exponencial e saturação nos *spots*, a PINN converge para a solução plana $u(x, y, t) \equiv u^* = 0,9000$.

Figura 1 — Dinâmica de treinamento e heterogeneidade: (a) convergência das componentes de perda $\mathcal{L}(\theta)$ da PINN ao longo de 20.000 épocas; e (b) evolução temporal da amplitude $\|u(t) - u^*\|_{L_2}$ evidenciando o crescimento físico no MDF ADI (Pereira, 2019) versus o colapso no atrator trivial na PINN.



Fonte: Elaboração própria.

Mecanismos Físico-Matemáticos da Falha da PINN: Três patologias explicam esse aprisionamento:

1. *Quebra da Causalidade Temporal e Retropropagação Espúria:* Na física real, a evolução temporal é estritamente causal. No treinamento da PINN, a amostragem ocorre simultaneamente em $\Omega \times [0, T]$. Como (u^*, v^*) zera a reação e a difusão, ele anula os resíduos da EDP para $t \gg 0$. Durante a retropropagação (*backpropagation*), esses gradientes associados a instantes futuros propagam-se através dos parâmetros θ até $t = 0$, funcionando como uma viscosidade numérica espúria que dissipa a perturbação inicial $\epsilon \sim 10^{-3}$ antes da amplificação física.

2. *Rigidez Cinética e Domínio no Hessiano:* Com $\kappa = 100$, a escala reativa $\tau_{\text{reac}} \sim 0,01$ s é muito mais veloz que a difusiva $\tau_{\text{dif}} \sim 20$ s. O gradiente $\nabla_{\theta} \mathcal{L}_{\text{pde}}$ é dominado pela reação, impondo o equilíbrio antes que a difusão segregue espécies.

3. *Viés Espectral contra Modos Críticos:* MLPs exibem viés espectral que prioriza baixas frequências espaciais. Como o modo de Turing reside em alta frequência ($k_c^2 \approx 135 \text{ rad}^2/\text{m}^2$), a rede amortece as oscilações dos padrões.

Confronto com o MDF ADI Linearizado de Pereira (2019): A Figura 2 e a Tabela 2 detalham o confronto direto. O MDF ADI de Pereira (2019) captura a expansão em $t = 0,02$ s, a quebra de simetria em $t = 0,41$ s e a cristalização dos *spots* em $t = 2,00$ s ($u \in [0,2134; 2,8305]$) em 9,59 s. A PINN consome 19,49 min em GPU e permanece estagnada em $u \approx 0,9000$, com erro relativo L_2 de 60,85%.

3 CONSIDERAÇÕES FINAIS


A investigação demonstra que o colapso de PINNs padrão na simulação de padrões de Turing decorre de patologias intrínsecas causadas pela violação da causalidade temporal, rigidez cinética e viés espectral. A amostragem global em $\Omega \times [0, T]$ converte o estado estacionário plano em um atrator espúrio de perda residual diminuta ($\sim 10^{-4}$), dissipando a instabilidade física via retropropagação de gradientes futuros. Em contrapartida, o método MDF ADI linearizado de Pereira (2019) comprova que a marcha causal sequencial é indispensável para sistemas morfogênicos, resolvendo a bifurcação em 9,59 s. Conclui-se que, para tornar PINNs viáveis em problemas de Turing, é imperativo adotar pesagens causais temporais, marcha discreta no tempo ou esquemas de continuação em κ .

Tabela 2 — Síntese comparativa metodológica e quantitativa: PINN Padrão versus MDF ADI Linearizado (Pereira, 2019).

Crítério de Avaliação	PINN Padrão (20.000 Épocas)	MDF ADI Linearizado (Pereira, 2019)
Integração Temporal	Espaço-tempo contínuo $\Omega \times [0, T]$	Marcha sequencial causal ($t^n \rightarrow t^{n+1}$)
Causalidade Física	Violada (retropropagação de resíduos futuros)	Estritamente preservada
Sensibilidade à Perturbação	Dissipada (atração para o estado plano)	Amplificada $\propto e^{\lambda t}$ (instabilidade real)
Resolução Numérica	Autograd e retropropagação (66.818 pesos)	Algoritmo de Thomas $\mathcal{O}(N)$ tridiagonal
Perda Residual / Erro	$\mathcal{L}_{\text{total}} = 1,95 \times 10^{-4}$ (Erro $L_2 = 60,85\%$)	Precisão $\mathcal{O}(\Delta t^2)$, convergente
Tempo Computacional	GPU (1.169,48 s / 19,49 min)	CPU (9,59 s em 128×128)
Faixa $u(t = 2,00 \text{ s})$	$u \in [0,8994; 0,9001]$ (Colapso uniforme)	$u \in [0,2134; 2,8305]$ (Spots nítidos)

Fonte: Elaboração própria.

Figura 2 — Confronto espaço-temporal e perfil transversal: (a) concentração 2D do ativador $u(x, y, t)$ via MDF ADI (Pereira, 2019) (linha superior) versus PINN Padrão (linha inferior) em $t \in \{0,02; 0,41; 2,00\} \text{ s}$; e (b) corte transversal horizontal em $y = 0,5 \text{ m}$ no instante final $t = 2,0 \text{ s}$.



Fonte: Elaboração própria.

REFERÊNCIAS

PEREIRA, Ricardo Reis. **Métodos de Diferenças Finitas para Problemas de Difusão e Reação Não Lineares**. 2019. Tese (Doutorado em Modelagem Computacional) – Laboratório Nacional de Computação Científica, Petrópolis, RJ. Disponível em <https://tede.lncc.br/handle/tede/313>. Acesso em: 20 ago. 2026.

TURING, Alan Mathison. The chemical basis of morphogenesis. **Philosophical Transactions of the Royal Society of London. Series B, Biological Sciences**, v. 237, n. 641, p. 37–72, 1952. Disponível em <https://doi.org/10.1098/rstb.1952.0012>.

MURRAY, James Dickson. **Mathematical Biology II: Spatial Models and Biomedical Applications**. 3. ed. New York: Springer, 2003. Disponível em <https://doi.org/10.1007/b98869>.

SCHNAKENBERG, Jürgen. Simple chemical reaction systems with limit cycle behaviour. **Journal of Theoretical Biology**, v. 81, n. 3, p. 389–400, 1979. Disponível em [https://doi.org/10.1016/0022-5193\(79\)90042-0](https://doi.org/10.1016/0022-5193(79)90042-0).

RAISSI, Maziar; PERDIKARIS, Paris; KARNIADAKIS, George Em. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. **Journal of Computational Physics**, v. 378, p. 686–707, 2019. Disponível em <https://doi.org/10.1016/j.jcp.2018.10.045>.