

REDES NEURAI INFORMADAS POR FÍSICA PARA RESOLUÇÃO NUMÉRICA DAS EQUAÇÕES BIDIMENSIONAIS DO CALOR E DE BURGERS

G. Warley B. Farias*

R. Reis Pereira**

RESUMO

A simulação computacional de sistemas físicos governados por Equações Diferenciais Parciais (EDPs) bidimensionais fundamenta a engenharia térmica e a fluidodinâmica. Esquemas clássicos de malha, como o Método de Diferenças Finitas (MDF) formalizado por Pereira (2019), enfrentam restrições de estabilidade (CFL) e elevado custo na discretização de geometrias complexas. Este trabalho investiga as Redes Neurais Informadas por Física (PINNs) como um paradigma contínuo e livre de malha (*meshless*) na resolução de dois problemas canônicos: a Equação do Calor 2D transiente linear ($\alpha = 0,1$) e a Equação de Burgers 2D viscosa ($\nu = 0,01$) sob condição inicial quadrupolar com quatro vórtices gaussianos convergentes. As leis de conservação física são integradas ao funcional de perda multiobjetivo via diferenciação automática (*autograd*) e retropropagadas para otimização dos pesos via Adam. Após 20.000 épocas, a PINN atinge resíduo $\mathcal{L}_{\text{total}} = 7,95 \times 10^{-5}$ no calor (erro relativo $\epsilon_{L^2} = 1,40 \times 10^{-3}$ ou 0,14% frente à solução analítica) e $\mathcal{L}_{\text{total}} = 1,04 \times 10^{-3}$ em Burgers ($\mathcal{L}_{\text{bc}} = 2,31 \times 10^{-6}$), capturando fielmente a dinâmica quadrupolar sem necessidade de malha.

Palavras-chave: redes neurais informadas por física; equação do calor; equação de burgers; equações diferenciais parciais; diferenciação automática

ODS: indústria, inovação e infraestrutura

ABSTRACT

Computational simulation of physical systems governed by two-dimensional Partial Differential Equations (PDEs) is fundamental to thermal engineering and fluid dynamics. Classical mesh-based schemes, such as the Finite Difference Method (FDM) formalized by Pereira (2019), face strict stability constraints (CFL) and high meshing overhead in complex geometries. This work investigates Physics-Informed Neural Networks (PINNs) as a continuous, mesh-free solver for two canonical problems: the linear transient 2D Heat Equation ($\alpha = 0.1$) and the nonlinear viscous 2D Burgers Equation ($\nu = 0.01$) under a quadrupolar initial condition with four converging Gaussian vortices. Physical conservation laws are directly embedded into a multi-objective loss function via automatic differentiation (*autograd*) and backpropagated for weight optimization using the Adam algorithm. After 20,000 epochs, the PINN achieves residuals of $\mathcal{L}_{\text{total}} = 7.95 \times 10^{-5}$ for heat (relative error $\epsilon_{L^2} = 1.40 \times 10^{-3}$ or 0.14% against analytical solution) and $\mathcal{L}_{\text{total}} = 1.04 \times 10^{-3}$ for Burgers ($\mathcal{L}_{\text{bc}} = 2.31 \times 10^{-6}$), accurately capturing quadrupolar dynamics without meshing.

Keywords: physics-informed neural networks; heat equation; Burgers equation; partial differential equations; automatic differentiation

SDG: industry, innovation and infrastructure

* warrley@alu.ufc.br

** reis@ufc.br

1 INTRODUÇÃO

A modelagem quantitativa de fenômenos de transporte térmico e dinâmica de fluidos descritos por **Equações Diferenciais Parciais (EDPs)** é indispensável no projeto de engenharia. Tradicionalmente, esquemas baseados em malha — como o **Método de Diferenças Finitas (MDF)**, Elementos Finitos (MEF) e Volumes Finitos (MVF) — transformam operadores diferenciais contínuos em sistemas algébricos via discretização nodal (Pereira, 2019). Em equações não lineares parabólicas e hiperbólicas, conforme formalizado por Pereira (2019), o MDF requer esquemas implícitos como o método ADI (Peaceman; Rachford, 1955) para mitigar restrições severas de estabilidade temporal ($CFL \leq 1/2$), demandando malhas estruturadas e acumulando erros de truncamento local $\mathcal{O}(\Delta x^2 + \Delta t^2)$ ao longo da marcha causal.

Em contrapartida, as **Redes Neurais Informadas por Física (PINNs)**, introduzidas por Raissi, Perdikaris e Karniadakis (2019), estabelecem uma abordagem contínua e livre de malha (*meshless*). A solução $u_\theta(\mathbf{x}, t)$ é parametrizada por um Perceptron Multicamadas (MLP) profundo, e os operadores diferenciais são avaliados exatamente no espaço contínuo por **diferenciação automática (autograd)**. As leis físicas e condições de fronteira compõem a função de perda multiobjetivo, contornando a discretização nodal e viabilizando inferências instantâneas $\mathcal{O}(1)$.

Este trabalho investiga o arcabouço PINN na resolução de duas EDPs canônicas 2D: (i) a **Equação do Calor 2D** transiente linear, validada quantitativamente frente à Série de Fourier; e (ii) a **Equação vetorial de Burgers 2D Viscosa** sob condição inicial quadrupolar (Burgers, 1948; Pereira, 2019). Analisam-se a dinâmica de perdas, a topologia de fluxos e os ganhos de inferência contínua.

2 DESENVOLVIMENTO

2.1 Fundamentação Teórica

1. Equação do Calor 2D: A condução térmica em sólido homogêneo $\Omega = [0, 1]^2$ com difusividade $\alpha = 0,1 \text{ m}^2/\text{s}$ no intervalo $t \in (0, 1, 0] \text{ s}$ é regida por:

$$\mathcal{R}_{\text{calor}}[u] := \frac{\partial u}{\partial t} - \alpha \left(\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} \right) = 0, \quad \forall (x, y, t) \in \Omega \times (0, 1, 0], \quad (1)$$

sob repouso inicial $u(x, y, 0) = 0, 0$ e contorno externo $u|_{\partial\Omega} = 1, 0$. A solução exata analítica por separação de variáveis é a série dupla de Fourier:

$$u^*(x, y, t) = 1, 0 - \sum_{m, n \text{ ímp.}}^{\infty} \frac{16}{\pi^2 m n} \sin(m\pi x) \sin(n\pi y) e^{-\alpha\pi^2(m^2+n^2)t}. \quad (2)$$

2. Equação de Burgers 2D Viscosa: O campo de velocidade $\mathbf{u} = [u, v]^\top$ em $\Omega = [-1, 1]^2$ com viscosidade $\nu = 0,01 \text{ m}^2/\text{s}$ satisfaz o sistema acoplado advectivo-difusivo (Burgers, 1948; Pereira, 2019):


$$\frac{\partial u}{\partial t} + u \frac{\partial u}{\partial x} + v \frac{\partial u}{\partial y} = \nu \nabla^2 u, \quad \frac{\partial v}{\partial t} + u \frac{\partial v}{\partial x} + v \frac{\partial v}{\partial y} = \nu \nabla^2 v, \quad (3)$$

com $\mathbf{u}|_{\partial\Omega} = \mathbf{0}$ e condição inicial quadrupolar composta por dois dipolos gaussianos ortogonais (4 vórtices convergentes ao centro):

$$u_0(x, y) = e^{-10[(x+0,3)^2+y^2]} - e^{-10[(x-0,3)^2+y^2]}, \quad v_0(x, y) = e^{-10[x^2+(y+0,3)^2]} - e^{-10[x^2+(y-0,3)^2]}. \quad (4)$$

Essa configuração impõe quatro polos de velocidade de pico $\|\mathbf{u}\| \approx 1,0$ m/s orientados para a origem $(0, 0)$, gerando uma zona de cisalhamento e colisão em cruz altamente desafiadora.

Figura 1 — Arquitetura e fluxo PINN: MLP profunda alimentada por coordenadas (x, y, t) , diferenciação automática exata via autograd e otimização multiobjetivo das perdas físicas.



Fonte: Elaboração própria.

3. Arquitetura Neural, Autograd e Retropropagação: A aproximação contínua $\mathbf{u}_\theta(\mathbf{z})$ com entrada $\mathbf{z} = [x, y, t]^\top \in \mathbb{R}^3$ é modelada por uma MLP de $L = 4$ camadas ocultas com $d_h = 64$ neurônios (Figura 1): $\mathbf{h}^{(1)} = \sigma(\mathbf{W}^{(1)}\mathbf{z} + \mathbf{b}^{(1)})$, $\mathbf{h}^{(\ell)} = \sigma(\mathbf{W}^{(\ell)}\mathbf{h}^{(\ell-1)} + \mathbf{b}^{(\ell)})$, $\mathbf{u}_\theta = \mathbf{W}^{(L+1)}\mathbf{h}^{(L)} + \mathbf{b}^{(L+1)}$, com ativação suave $\sigma(s) = \tanh(s) \in C^\infty(\mathbb{R})$. O treinamento articula um duplo fluxo de gradientes: (i) a **diferenciação automática (autograd)** em relação a $\mathbf{z}$ avalia exatamente as derivadas parciais da EDP via produtos vetor-Jacobiano (VJP): $\frac{\partial \mathbf{u}_\theta}{\partial x_j} = \nabla_{\mathbf{z}} \mathbf{u}_\theta \cdot \mathbf{e}_j$ e $\frac{\partial^2 \mathbf{u}_\theta}{\partial x_j^2} = \nabla_{\mathbf{z}} (\frac{\partial \mathbf{u}_\theta}{\partial x_j}) \cdot \mathbf{e}_j$; e (ii) o algoritmo de **retropropagação (backpropagation)** propaga o resíduo do funcional $\mathcal{L}(\theta)$ pelas camadas para computar $\nabla_\theta \mathcal{L}(\theta)$ e atualizar os pesos sinápticos via otimização estocástica.

2.2 Metodologia

A otimização minimiza os parâmetros θ sob o funcional multiobjetivo ponderado L_2 :

$$\mathcal{L}(\theta) = \lambda_{\text{pde}} \mathcal{L}_{\text{pde}}(\theta) + \lambda_{\text{ic}} \mathcal{L}_{\text{ic}}(\theta) + \lambda_{\text{bc}} \mathcal{L}_{\text{bc}}(\theta), \quad (5)$$

com $\mathcal{L}_{\text{pde}} = \frac{1}{N_f} \sum \|\mathcal{R}[\mathbf{u}_\theta]\|_2^2$, $\mathcal{L}_{\text{ic}} = \frac{1}{N_0} \sum \|\mathbf{u}_\theta - \mathbf{u}_0\|_2^2$, $\mathcal{L}_{\text{bc}} = \frac{1}{N_b} \sum \|\mathbf{u}_\theta - \mathbf{g}\|_2^2$ e $\lambda_{\text{pde}} = \lambda_{\text{ic}} = \lambda_{\text{bc}} = 1,0$. A Tabela 1 sumariza os parâmetros experimentais adotados no treinamento (20.000 épocas Adam com $\eta = 10^{-3}$).

Tabela 1 — Parâmetros experimentais e hiperparâmetros de rede para Calor 2D e Burgers 2D.

Hiperparâmetro / Configuração	Equação do Calor 2D	Equação de Burgers 2D
Arquitetura Neural	MLP (4 × 64, tanh)	MLP (4 × 64, tanh)
Dimensão Entrada / Saída	$(x, y, t) \in \mathbb{R}^3 \rightarrow u \in \mathbb{R}$	$(x, y, t) \in \mathbb{R}^3 \rightarrow (u, v) \in \mathbb{R}^2$
Parâmetros Treináveis (N_θ)	12.865	12.930
Pontos de Colocação ($N_f/N_0/N_b$)	10.000 / 10.000 / 4.000	10.000 / 10.000 / 4.000
Parâmetro Físico Fundamental	$\alpha = 0,1 \text{ m}^2/\text{s}$	$\nu = 0,01 \text{ m}^2/\text{s}$
Domínio Espaço-Temporal	$[0, 1]^2 \times [0, 1, 0] \text{ s}$	$[-1, 1]^2 \times [0, 1, 0] \text{ s}$
Condição de Contorno	Dirichlet $u _{\partial\Omega} = 1,0$	Dirichlet $\mathbf{u} _{\partial\Omega} = \mathbf{0}$
Otimizador e Épocas	Adam ($\eta = 10^{-3}$, 20.000 épocas)	Adam ($\eta = 10^{-3}$, 20.000 épocas)


Fonte: Elaboração própria.

2.3 Resultados e Discussão

Dinâmica de Convergência das Perdas: A trajetória das componentes de perda ao longo das 20.000 iterações é apresentada na Figura 2. No problema do calor (Figura 2(a)), a linearidade assegura rápido decaimento assintótico, atingindo $\mathcal{L}_{\text{total}} = 7,95 \times 10^{-5}$ com resíduo

da EDP $\mathcal{L}_{\text{pde}} = 6,47 \times 10^{-5}$. Em Burgers (Figura 2(b)), as bordas homogêneas viabilizam $\mathcal{L}_{\text{bc}} = 2,31 \times 10^{-6}$ e resíduo total $\mathcal{L}_{\text{total}} = 1,04 \times 10^{-3}$, confirmando o ajuste estrito das restrições físicas.


Figura 2 — Curvas de convergência semilogarítmica do treinamento da PINN ao longo de 20.000 épocas: (a) Equação do Calor 2D ($\alpha = 0,1 \text{ m}^2/\text{s}$); e (b) Equação de Burgers 2D ($\nu = 0,01 \text{ m}^2/\text{s}$).



Fonte: Elaboração própria.

Experimento 1 — Difusão Térmica 2D e Validação Analítica: A Figura 3 ilustra a evolução da superfície $u_\theta(x, y, t)$ em quatro instantes temporais. Em $t = 0,0 \text{ s}$, a rede capta a base fria $u = 0$ com contornos quentes $u = 1$. Com o avanço do tempo ($t = 0,3 \rightarrow 0,7 \rightarrow 1,0 \text{ s}$), a difusão penetra homogeneamente ao centro. A validação frente à solução analítica em malha 100×100 comprova erro relativo $\epsilon_{L^2} = 1,40 \times 10^{-3}$ (0,14%) e erro máximo $\epsilon_{L^\infty} = 1,29 \times 10^{-3}$.

Figura 3 — Equação do Calor 2D: evolução da distribuição de temperatura em superfície tridimensional $u_\theta(x, y, t)$ predita pela PINN para $t \in \{0,0; 0,3; 0,7; 1,0\} \text{ s}$ ($\alpha = 0,1 \text{ m}^2/\text{s}$).




Fonte: Elaboração própria.

Experimento 2 — Dinâmica Não Linear dos Vórtices de Burgers 2D: A Figura 4 exibe a interação advectivo-difusiva da estrutura quadrupolar. Em $t = 0,0 \text{ s}$ (Figura 4(a)), o campo de magnitude $\|\mathbf{u}\| = \sqrt{u^2 + v^2}$ revela quatro lóbulos simétricos de velocidade concentrados em $(\pm 0,3, 0)$ e $(0, \pm 0,3)$ com $\|\mathbf{u}\| \approx 1,0 \text{ m/s}$, direcionados simultaneamente para a origem. Em $t = 0,3 \text{ s}$ (Figura 4(b)), a advecção não linear $(\mathbf{u} \cdot \nabla)\mathbf{u}$ atrai os quatro núcleos, deflagrando uma frente de colisão central em cruz com gradientes pronunciados. Em $t = 0,5 \text{ s}$ (Figura 4(c)), ocorre a coalescência dos vórtices sob forte cisalhamento e rotação local. Em $t = 1,0 \text{ s}$ (Figura 4(d)), a dissipação viscosa ($\nu = 0,01 \text{ m}^2/\text{s}$) amortece o fluxo para $\|\mathbf{u}\| \approx 0,18 \text{ m/s}$ sem gerar instabilidades numéricas.

Análise Comparativa e Desempenho Computacional: A Tabela 2 consolida os resultados quantitativos. Enquanto esquemas clássicos de diferenças finitas investigados por Pereira (2019) impõem avanços passo a passo com restrições de estabilidade CFL e interpolações nodais que degradam gradientes íngremes, a PINN resolve todo o bloco espaço-temporal $\Omega \times [0, T]$ em um bloco unificado. Uma vez ajustados os tensores θ , a avaliação contínua para 10.000 coordenadas arbitrárias em GPU requer meros 1,09 ms no calor e 2,45 ms em Burgers. A ativação $\tanh \in C^\infty$ permite extrair instantaneamente grandezas derivadas exatas via autograd (como fluxos térmicos $\mathbf{q} = -\kappa \nabla u$, vorticidade $\omega = \frac{\partial v}{\partial x} - \frac{\partial u}{\partial y}$ e dissipação viscosa $\varepsilon = \nu \|\nabla \mathbf{u}\|^2$) sem aproximações numéricas adicionais.

Figura 4 — Equação de Burgers 2D: sequência de colisão e coalescência dos quatro vórtices gaussianos com magnitude de velocidade $\|\mathbf{u}\|$ e vetores de fluxo nos instantes $t \in \{0,0; 0,3; 0,5; 1,0\}$ s ($\nu = 0,01 \text{ m}^2/\text{s}$).



Fonte: Elaboração própria.

Tabela 2 — Síntese dos indicadores quantitativos de convergência e desempenho das PINNs.

Indicador Quantitativo de Desempenho	Calor 2D ($\alpha = 0,1$)	Burgers 2D ($\nu = 0,01$)
Perda Total Final ($\mathcal{L}_{\text{total}}$)	$7,95 \times 10^{-5}$	$1,04 \times 10^{-3}$
Resíduo da EDP ($\mathcal{L}_{\text{pde}}$)	$6,47 \times 10^{-5}$	$8,23 \times 10^{-4}$
Resíduo de Contorno ($\mathcal{L}_{\text{bc}}$)	$4,36 \times 10^{-7}$	$2,31 \times 10^{-6}$
Resíduo de Condição Inicial ($\mathcal{L}_{\text{ic}}$)	$3,04 \times 10^{-7}$	$8,71 \times 10^{-6}$
Erro Relativo (ϵ_{L^2})	$1,40 \times 10^{-3}$ (0,14%)	—
Erro Máximo (ϵ_{L^∞})	$1,29 \times 10^{-3}$	—
Tempo de Inferência (10^4 pontos)	1,09 ms	2,45 ms
Parâmetros / Tamanho do Modelo	12.865 (198 kB)	12.930 (202 kB)

Fonte: Elaboração própria.

3 CONSIDERAÇÕES FINAIS

Os resultados comprovam que as Redes Neurais Informadas por Física constituem uma metodologia precisa, compacta e eficiente para a resolução de EDPs lineares parabólicas (Calor 2D) e sistemas acoplados fortemente não lineares (Burgers 2D). A sinergia entre o cálculo exato de operadores diferenciais via autograd e a retropropagação (*backpropagation*) do funcional multiobjetivo supera os gargalos clássicos de discretização do MDF formalizados por Pereira (2019). A validação analítica comprova erro relativo inferior a 0,15%, enquanto o experimento de Burgers confirma a captura estável da dinâmica de colisão quadrupolar e amortecimento viscoso sustentada por perdas residuais $\mathcal{L}_{\text{total}} \sim 10^{-3}$. O custo inicial de treinamento em GPU é amplamente amortizado pela inferência ultrarrápida em escala de milissegundos ($\sim 1 \dots 2,5$ ms). Trabalhos futuros incluem problemas inversos de estimação paramétrica e escoamentos turbulentos 3D.

REFERÊNCIAS

PEREIRA, Ricardo Reis. **Métodos de Diferenças Finitas para Problemas de Difusão e Reação Não Lineares**. 2019. Tese (Doutorado) – Laboratório Nacional de Computação Científica (LNCC), Petrópolis, RJ.

PEACEMAN, Donald Wildon; RACHFORD, Henry Harold. The numerical solution of parabolic and elliptic differential equations. **Journal of the Society for Industrial and Applied Mathematics**, v. 3, n. 1, p. 28–41, 1955.

RAISSI, Maziar; PERDIKARIS, Paris; KARNIADAKIS, George Em. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. **Journal of Computational Physics**, Elsevier, v. 378, p. 686–707, 2019.

BURGERS, Johannes Martinus. A mathematical model illustrating the theory of turbulence. **Advances in Applied Mechanics**, Elsevier, v. 1, p. 171–199, 1948.