

REDES NEURAIIS INFORMADAS POR FÍSICA EM GEOMETRIAS COMPLEXAS: ANÁLISE COMPARATIVA FRENTE AO MÉTODO ADI NA EQUAÇÃO DO CALOR 2D

Preencher nomes e emails apenas após aprovação
Autoria omitida para avaliação duplo-cega
 Campus da Universidade Federal do Ceará em Quixadá

RESUMO

A simulação da condução térmica transiente em sólidos com geometrias complexas e múltiplos sumidouros perfurados impõe severos desafios aos esquemas numéricos clássicos. O Método de Diferenças Finitas (MDF) com Direções Alternadas Implícitas (ADI), formalizado por Pereira (2019), exibe custo computacional linear ótimo $\mathcal{O}(N)$ em malhas cartesianas regulares, mas sofre degradação pelo erro de escadamento (*staircasing*) e quebra da fatoração tridiagonal em contornos curvos. Este trabalho investiga as Redes Neurais Informadas por Física (PINNs) como um resolvidor contínuo e livre de malha (*meshless*) para a Equação do Calor bidimensional em um domínio multiconectado com três cavidades circulares dissipadoras. A topologia geométrica é assimilada no funcional de perda multiobjetivo ponderada via diferenciação automática (*autograd*). Após 50.000 épocas de otimização Adam, a PINN solidifica as barreiras de Dirichlet nos furos com erro residual na ordem de $2,43 \times 10^{-6}$, superando as descontinuidades de malha. Analisam-se a rigidez de gradiente (*stiffness*) próxima à época 26.000, o relevo contínuo subjacente nas cavidades desmascaradas e as limitações da inferência global espaço-temporal frente à marcha causal sequencial de Pereira (2019).

Palavras-chave: redes neurais informadas por física; equação do calor; método de diferenças finitas; direções alternadas implícitas; erro de escadamento

ODS: indústria, inovação e infraestrutura

ABSTRACT

Transient thermodynamic modeling in solid media with complex geometries and multiple cooling cavities imposes severe challenges on classical numerical schemes. The Finite Difference Method (FDM) based on the Alternating Direction Implicit (ADI) scheme, extensively formalized by Pereira (2019), achieves optimal $\mathcal{O}(N)$ complexity on regular Cartesian grids, but suffers from staircasing errors and breakdown of tridiagonal factorization on curved boundaries. This paper investigates Physics-Informed Neural Networks (PINNs) as a continuous, mesh-free solver for the 2D heat equation in a multiply connected domain containing three circular cooling cavities. Boundary manifolds are analytically assimilated into a weighted multi-objective loss function via automatic differentiation. After 50,000 epochs of Adam optimization, the PINN enforces Dirichlet sink boundaries with residual errors around 2.43×10^{-6} , completely circumventing grid-staircasing artifacts. We further analyze the gradient stiffness pathology around epoch 26,000, examine the unmasked continuous mathematical depression inside cavities, and evaluate the intrinsic limitations of global space-time block optimization under blind temporal extrapolation versus the causal time-marching of Pereira (2019).

Keywords: physics-informed neural networks; heat equation; finite difference method; alternating direction implicit; staircasing error

SDG: industry, innovation and infrastructure

1 INTRODUÇÃO

A modelagem quantitativa da difusão térmica transiente em domínios espaciais multiconectados desempenha papel fulcral no projeto de trocadores de calor, sistemas microeletromecânicos e gerenciamento térmico de circuitos integrados com múltiplos canais dissipadores. Historicamente, o **Método de Diferenças Finitas (MDF)** consolidou-se como a ferramenta preponderante para a integração temporal de **Equações Diferenciais Parciais (EDPs)** parabólicas, impulsionado pelo consagrado esquema de **Direções Alternadas Implícitas (ADI)** de Peaceman e Rachford Jr (1955), cujos fundamentos teóricos e estabilidade numérica foram formalizados para problemas não lineares de transporte e reação-difusão na tese de Pereira (2019).

Em geometrias cartesianas retangulares uniformes, o método ADI decompõe o operador Laplaciano bidimensional em passos unidimensionais implícitos sucessivos de meia etapa temporal. Essa formulação desacopla as coordenadas espaciais em sistemas tridiagonais estritamente diagonais dominantes, resolvidos pelo Algoritmo de Thomas com complexidade linear $\mathcal{O}(N)$ e estabilidade incondicional de von Neumann (Peaceman; Rachford Jr, 1955; Pereira, 2019).

No entanto, a eficiência matricial do ADI cessa diante de geometrias com contornos curvos ou não ortogonais. Em grades cartesianas, a representação de superfícies radiais induz o **erro de escadeamento (staircasing)**, no qual contornos suaves são aproximados por degraus ortogonais descontínuos. Essa discretização espúria introduz um erro geométrico de truncamento de primeira ordem $\mathcal{O}(\Delta x)$ nos vetores normais $\mathbf{n}$, contaminando o cômputo dos fluxos térmicos $-\kappa \nabla u \cdot \mathbf{n}$. Como apontado por Pereira (2019), esquemas corretivos de contorno irregular (como a aproximação de Shortley-Weller) quebram a estrutura de produto tensorial das matrizes direcionais, inviabilizando a fatoração tridiagonal rápida e exigindo resolvidores iterativos esparsos de alto custo $\mathcal{O}(N^{1,5} \dots N^2)$.

Nesse contexto, as **Redes Neurais Informadas por Física (PINNs)**, introduzidas por Raissi, Perdikaris e Karniadakis (2019), despontam como uma abordagem livre de malha (*meshless*) estritamente contínua. Ao parametrizar o campo térmico por um **Perceptron Multicamadas (MLP)** e avaliar os operadores diferenciais da EDP via diferenciação automática exata (*autograd*), as PINNs eliminam reticulados discretos. Os pontos colacionais de contorno são distribuídos diretamente sobre as variedades analíticas contínuas das cavidades, mitigando integralmente o erro de escadeamento.

Este trabalho apresenta uma análise comparativa aprofundada entre o método ADI clássico investigado por Pereira (2019) e o paradigma PINN de Raissi, Perdikaris e Karniadakis (2019) na solução da Equação do Calor 2D em uma chapa contendo três cavidades dissipadoras circulares. Analisam-se a dinâmica de convergência, a rigidez de gradiente (*gradient stiffness*) no treinamento multiobjetivo, o relevo contínuo sem máscaras e a capacidade extrapolativa temporal de ambos os paradigmas.

2 DESENVOLVIMENTO

2.1 Fundamentação Teórica

Definição do Problema de Valor Inicial e de Contorno (PVIC): Seja $\Omega \subset \mathbb{R}^2$ o domínio multiconectado de uma chapa unitária $[0, L]^2$ ($L = 1,0$ m) da qual foram subtraídas $K = 3$ cavidades circulares disjuntas $\mathcal{H}_k$:

$$\Omega = [0, L]^2 \setminus \bigcup_{k=1}^K \mathcal{H}_k, \quad \mathcal{H}_k = \left\{ (x, y) \in \mathbb{R}^2 \mid (x - x_c^{(k)})^2 + (y - y_c^{(k)})^2 \leq r_k^2 \right\}, \quad (1)$$

com centros $\mathbf{x}_c^{(1)} = (0,30; 0,30)$, $\mathbf{x}_c^{(2)} = (0,70; 0,30)$, $\mathbf{x}_c^{(3)} = (0,50; 0,70)$ e raio $r_k = 0,12$ m. A condução térmica com difusividade $\alpha = 0,05$ m²/s no horizonte $t \in (0, T]$ ($T = 2,0$ s) é regida por:

$$\mathcal{R}_u(x, y, t) := \frac{\partial u}{\partial t} - \alpha \nabla^2 u = \frac{\partial u}{\partial t} - \alpha \left(\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} \right) = 0, \quad \forall (x, y, t) \in \Omega \times (0, T]. \quad (2)$$


Adotam-se condição inicial de repouso $u(x, y, 0) = 0,0$, bordas externas sob temperatura prescrita $u|_{\partial\Omega_{\text{ext}}} = 1,0$ e contornos das cavidades resfriados $u|_{\partial\mathcal{H}_k} = 0,0$.

O Esquema ADI Clássico e a Degradação em Contornos Curvos: Na discretização por diferenças finitas com passos $\Delta x, \Delta y, \Delta t$, o esquema Peaceman-Rachford ADI formalizado por Peaceman e Rachford Jr (1955) e detalhado em Pereira (2019) decompõe o Laplaciano em passos unidimensionais implícitos sucessivos:

$$\left(I - \frac{\alpha\Delta t}{2}\delta_x^2\right) u_{i,j}^{n+1/2} = \left(I + \frac{\alpha\Delta t}{2}\delta_y^2\right) u_{i,j}^n, \quad \left(I - \frac{\alpha\Delta t}{2}\delta_y^2\right) u_{i,j}^{n+1} = \left(I + \frac{\alpha\Delta t}{2}\delta_x^2\right) u_{i,j}^{n+1/2}. \quad (3)$$

Eliminando o estado intermediário $u_{i,j}^{n+1/2}$, obtém-se o operador global fatorado de ordem $\mathcal{O}(\Delta t^2 + \Delta x^2 + \Delta y^2)$ com estabilidade incondicional de von Neumann em malhas regulares (Pereira, 2019).

Figura 1 — Comparativo geométrico entre a malha cartesiana (com erro de escadeamento) e a amostragem contínua livre de malha da PINN.



Fonte: Elaboração própria.

Contudo, como ilustrado na Figura 1(a), a presença das cavidades curvas $\partial\mathcal{H}_k$ impõe o erro de escadeamento (*staircasing*), onde o contorno suave é aproximado por degraus ortogonais, degradando a acurácia dos fluxos normais $-\kappa\nabla u \cdot \mathbf{n}$ para $\mathcal{O}(\Delta x)$. Conforme examinado por Pereira (2019), correções por células de corte (fórmula de Shortley-Weller com distâncias $\theta_x\Delta x$) destroem a simetria direcional tridiagonal, impedindo o uso do algoritmo de Thomas e elevando a complexidade para $\mathcal{O}(N^{1,5} \dots N^2)$.

Arquitetura da PINN, Diferenciação Automática e Retropropagação: A formulação PINN de Raissi, Perdikaris e Karniadakis (2019) aproxima o campo escalar contínuo $\hat{u}_\theta(x, y, t)$ por uma MLP profunda alimentada pelo vetor $\mathbf{z} = [x, y, t]^\top \in \mathbb{R}^3$, operando ao longo de $L = 4$ camadas ocultas de largura 128:

$$\mathbf{h}^{(0)} = \mathbf{z}, \quad \mathbf{h}^{(\ell)} = \sigma(\mathbf{W}^{(\ell)}\mathbf{h}^{(\ell-1)} + \mathbf{b}^{(\ell)}), \quad \hat{u}_\theta(\mathbf{z}) = \mathbf{W}^{(L+1)}\mathbf{h}^{(L)} + \mathbf{b}^{(L+1)}, \quad (4)$$

totalizando $N_\theta = 66.689$ parâmetros treináveis inicializados via Xavier Normal. Adotou-se a ativação suave $\sigma(z) = \tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}} \in C^\infty(\mathbb{R})$. O treinamento articula um duplo fluxo de gradientes: (i) a **diferenciação automática (autograd)** em relação às coordenadas de entrada $\mathbf{z}$ avalia exatamente os termos diferenciais da EDP $\frac{\partial \hat{u}_\theta}{\partial t}$ e $\nabla^2 \hat{u}_\theta = \frac{\partial^2 \hat{u}_\theta}{\partial x^2} + \frac{\partial^2 \hat{u}_\theta}{\partial y^2}$ por produtos vetor-Jacobiano sem malha; e (ii) o algoritmo de **retropropagação (backpropagation)** propaga o erro do funcional de perda multiobjetivo $\mathcal{L}(\theta)$ pelas camadas da rede para computar $\nabla_\theta \mathcal{L}(\theta) = [\frac{\partial \mathcal{L}}{\partial \mathbf{W}^{(\ell)}}, \frac{\partial \mathcal{L}}{\partial \mathbf{b}^{(\ell)}}]$ e atualizar os pesos sinápticos via otimização estocástica.

2.2 Metodologia

A amostragem de pontos colacionais opera diretamente sobre variedades contínuas (Figura 1(b)):

- $N_f = 30.000$ pontos internos $\mathbf{z}_i^f \in \Omega \times (0, T]$, sendo 24.000 homogêneos e 6.000 (20%) refinados na camada limite anular $r \in [r_k, r_k + 0,05]$ ao redor dos furos ($\|\nabla u \cdot \mathbf{n}\| \approx 4,2 \text{ m}^{-1}$);

- $N_{\text{ic}} = 5.000$ pontos em $t = 0$; $N_{\text{ext}} = 8.000$ pontos nas arestas externas $\partial\Omega_{\text{ext}} \times (0, T]$;
- $N_{\text{furos}} = 6.000$ pontos no contorno polar exato: $\mathbf{x}_{\partial\mathcal{H}_k}(\theta_p) = (x_c^{(k)} + r_k \cos \theta_p, y_c^{(k)} + r_k \sin \theta_p)^\top$.

O funcional multiobjetivo global ponderado $\mathcal{L}(\theta)$ é formulado na métrica L_2 :

$$\mathcal{L}(\theta) = \lambda_{\text{pde}} \mathcal{L}_{\text{pde}}(\theta) + \lambda_{\text{ic}} \mathcal{L}_{\text{ic}}(\theta) + \lambda_{\text{ext}} \mathcal{L}_{\text{ext}}(\theta) + \lambda_{\text{furos}} \mathcal{L}_{\text{furos}}(\theta), \quad (5)$$

com $\mathcal{L}_{\text{pde}} = \frac{1}{N_f} \sum \|\frac{\partial \hat{u}_\theta}{\partial t} - \alpha \nabla^2 \hat{u}_\theta\|_{L_2}^2$, $\mathcal{L}_{\text{ic}} = \frac{1}{N_{\text{ic}}} \sum \|\hat{u}_\theta - 0\|_{L_2}^2$, $\mathcal{L}_{\text{ext}} = \frac{1}{N_{\text{ext}}} \sum \|\hat{u}_\theta - 1\|_{L_2}^2$ e $\mathcal{L}_{\text{furos}} = \frac{1}{N_{\text{furos}}} \sum \|\hat{u}_\theta - 0\|_{L_2}^2$. Fixaram-se $\lambda_{\text{pde}} = 1,0$, $\lambda_{\text{ic}} = \lambda_{\text{ext}} = 20,0$ e $\lambda_{\text{furos}} = 40,0$.

O treinamento estendeu-se por 50.000 épocas em GPU (RTX 3050, consumo $< 1,2$ GB VRAM) via algoritmo Adam acoplado a *Cosine Annealing* ($\eta = 10^{-3} \rightarrow 10^{-5}$, 104,2 ms/época e 86,8 min totais).

2.3 Resultados e Discussão

A Tabela 1 consolida os resíduos finais atingidos pela PINN após as 50.000 iterações de otimização.

Tabela 1 — Métricas residuais finais da PINN na Equação do Calor 2D após 50.000 épocas.

Componente	$\mathcal{L}_{\text{total}}$	$\mathcal{L}_{\text{pde}}$	$\mathcal{L}_{\text{ic}}$	$\mathcal{L}_{\text{ext}}$	$\mathcal{L}_{\text{furos}}$
Valor Residual (L_2)	$9,13 \times 10^{-3}$	$8,56 \times 10^{-4}$	$1,58 \times 10^{-4}$	$2,51 \times 10^{-4}$	$2,43 \times 10^{-6}$

Fonte: Elaboração própria.

Dinâmica de Perdas, Relevô Contínuo e Extrapolação: A forte penalização de contorno ($\lambda_{\text{furos}} = 40,0$) gera matrizes Hessianas mal-condicionadas. A Figura 2(a) ilustra em destaque a trajetória assintótica de convergência. As estimativas de momento do Adam ($\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{\hat{v}_t + \epsilon}} \hat{m}_t$), ao cruzarem vales estreitos na superfície de perda, acumulam inércia direcional em $\hat{m}_t$. Próximo à época 26.000, essa rigidez numérica impeliu o estado contra paredes de curvatura abrupta, gerando uma oscilação transitória antes de reatar a convergência monotônica estável.

Como a PINN gera um campo $\hat{u}_\theta \in C^\infty(\mathbb{R}^3)$, ela interpola valores em todo o $\mathbb{R}^3$, inclusive no interior oco das cavidades $\mathcal{H}_k$. As Figuras 2(b) e 2(c) ilustram o estado em $t = 2,0$ s sem máscara visual: para fixar a condição nula $\hat{u}_\theta|_{\partial\mathcal{H}_k} = 0$ sob fortes gradientes aquecidos ($u = 1,0$), as bases tanh mergulham em um afundamento analítico contínuo ($\hat{u} \approx -0,8$). Por outro lado, a Figura 2(d) evidencia o colapso físico fora do suporte sob extrapolação cega para $t = 5,0$ s ($T_{\text{max}} = 2,0$ s).

Comparativo Estrutural e Viés na Extrapolação Temporal: A Tabela 2 sintetiza o confronto global entre os esquemas. A PINN otimiza o hiperbloco $\Omega \times [0, T]$ de forma holística, realizando inferências diretas em 2,1 ms sem acumular erros pretéritos. Todavia, sob extrapolação temporal, a rede falha por quebra de suporte colacional, ao passo que o esquema ADI de Pereira (2019) avança estavelmente por marcha causal indefinida.


3 CONSIDERAÇÕES FINAIS

A formulação de Redes Neurais Informadas por Física superou com êxito o erro de escadamento e a quebra da fatoração tridiagonal característicos do método ADI em geometrias perfuradas, assegurando erro residual de $2,43 \times 10^{-6}$ no contorno dos sumidouros térmicos. A parametrização analítica aliada ao *autograd* dispensa malhas e viabiliza inferências instantâneas $\mathcal{O}(1)$. Identificou-se, contudo, a suscetibilidade do otimizador Adam a rigidezes de gradiente em vales estreitos e o colapso na extrapolação temporal fora da janela treinada. Enquanto o método ADI investigado na tese de Pereira (2019) preserva a superioridade absoluta na marcha temporal longa em geometrias regulares, as PINNs consolidam-se como alternativa promissora para domínios irregulares complexos, incentivando pesquisas em esquemas causalmente recursivos.

Tabela 2 — Síntese comparativa estrutural: Método ADI (Pereira, 2019) versus PINN contínua.

Critério de Avaliação	MDF ADI (Pereira, 2019)	PINN (<i>Meshless</i>)
Discretização Espaço-Temporal	Malha cartesiana ($\Delta x, \Delta y, \Delta t$)	Espaço-tempo contínuo $\Omega \times [0, T]$
Fronteiras Curvas ($\partial\mathcal{H}_k$)	Escadamento $\mathcal{O}(\Delta x)$	Colocação polar analítica exata
Custo Algébrico por Passo	$\mathcal{O}(N)$ linear (Thomas)	Treinamento em GPU (50k épocas, 1,18 GB)
Tempo de Inferência (200×200)	Marcha (85,4 ms em 2000 passos)	Avaliação direta (2,1 ms para $\forall t \leq T$)
Estabilidade de Marcha	Incondicional (L_2 von Neumann)	Sujeita a rigidez de gradiente (<i>stiffness</i>)
Capacidade Extrapolativa ($t > T$)	Marcha causal natural $t_{n+1} = t_n + \Delta t$	Falha grave por perda de suporte colacional

Fonte: Elaboração própria.

Figura 2 — Diagnóstico completo da PINN: (a) curva de perdas multiobjetivo ao longo de 50.000 épocas; (b) campo 2D contínuo sem máscara em $t = 2,0$ s; (c) perspectiva 3D com depressão analítica; e (d) extrapolação cega para $t = 5,0$ s.

Fonte: Elaboração própria.

REFERÊNCIAS

PEACEMAN, Donald W; RACHFORD JR, Henry H. The numerical solution of parabolic and elliptic differential equations. **Journal of the Society for Industrial and Applied Mathematics**, SIAM, v. 3, n. 1, p. 28–41, 1955. DOI: 10.1137/0103003. Disponível em <https://doi.org/10.1137/0103003>.

PEREIRA, Ricardo Reis. **Métodos de Diferenças Finitas para Problemas de Difusão e Reação Não Lineares**. 2019. Tese (Doutorado em Modelagem Computacional) – Laboratório Nacional de Computação Científica, Petrópolis, RJ. Disponível em <https://tede.lncc.br/handle/tede/313>. Acesso em: 20 ago. 2026.

RAISSI, Maziar; PERDIKARIS, Paris; KARNIADAKIS, George Em. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. **Journal of Computational Physics**, Elsevier, v. 378, p. 686–707, 2019. DOI: 10.1016/j.jcp.2018.10.045. Disponível em <https://doi.org/10.1016/j.jcp.2018.10.045>.