

O PAPEL DA CAUSALIDADE TEMPORAL E DA RIGIDEZ NUMÉRICA NA FALHA DE PINNS PARA PADRÕES DE TURING: UMA ANÁLISE CRÍTICA DO MODELO DE SCHNAKENBERG

Autor Principal*
Orientador**

RESUMO

Este artigo investiga as causas fundamentais pelas quais as Redes Neurais Informadas por Física (PINNs) em formulação padrão (*vanilla*) falham na simulação direta (*forward*) de padrões de Turing no modelo de reação-difusão de Schnakenberg. Com base nos parâmetros exatos da tese de Pereira (2019) ($D_v/D_u = 20, \kappa = 100$ no domínio $\Omega = [0, 1]^2$), conduziram-se experimentos com uma Pure MLP profunda de 5 camadas ocultas (66.818 parâmetros) treinada por 20.000 épocas na GPU. Demonstra-se o paradoxo da convergência espúria: a despeito de atingir uma perda residual global muito baixa ($\mathcal{L}_{\text{total}} = 1,95 \times 10^{-4}$) e resíduo inicial quase nulo ($\mathcal{L}_{\text{ic}} = 4,02 \times 10^{-8}$), a rede colapsa integralmente para o estado estacionário homogêneo trivial ($u^* = 0,90$), incorrendo em um erro L_2 relativo de 60,85% em relação à solução de referência. Identificam-se três patologias estruturais: (i) a quebra da causalidade temporal pela amostragem simultânea em $\Omega \times [0, T]$; (ii) a rigidez cinética e difusiva; e (iii) o viés espectral da MLP. Em contrapartida, revisita-se o Método de Diferenças Finitas (MDF) com Direções Alternadas Implícitas (ADI) linearizado de Pereira (2019), cuja marcha causal estrita garante estabilidade incondicional, ordem $\mathcal{O}(\Delta t^2)$ e resolução exata dos *spots* em apenas 9,59 s.

Palavras-chave: redes neurais informadas por física; causalidade temporal; instabilidade de Turing; modelo de Schnakenberg; rigidez numérica; método de diferenças finitas; direções alternadas implícitas

ODS: indústria, inovação e infraestrutura

ABSTRACT

This paper investigates the fundamental causes behind the failure of standard (*vanilla*) Physics-Informed Neural Networks (PINNs) in forward simulations of Turing patterns within the Schnakenberg model. Using the exact parameters from the thesis of Pereira (2019) ($D_v/D_u = 20, \kappa = 100$ on the domain $\Omega = [0, 1]^2$), experiments were performed with a deep Pure MLP of 5 hidden layers (66,818 parameters) trained for 20,000 epochs on GPU. We demonstrate the spurious convergence paradox: despite reaching a very low residual loss ($\mathcal{L}_{\text{total}} = 1.95 \times 10^{-4}$) and negligible initial residual ($\mathcal{L}_{\text{ic}} = 4.02 \times 10^{-8}$), the network collapses into the trivial homogeneous state ($u^* = 0.90$), yielding a relative L_2 error of 60.85%. Three interdependent pathologies are established: (i) temporal causality violation from global space-time sampling; (ii) kinetic and diffusive stiffness; and (iii) spectral bias against critical wavenumbers. In contrast, the Finite Difference Method (FDM / MDF) coupled with Linearized Alternating Direction Implicit (ADI) time-marching from Pereira (2019) preserves causal evolution, ensuring unconditional stability, $\mathcal{O}(\Delta t^2)$ order, and faithful spot formation in 9.59 s.

Keywords: physics-informed neural networks; temporal causality; Turing instability; Schnakenberg model; numerical stiffness; finite difference method; alternating direction implicit

SDG: industry, innovation and infrastructure

* autor@alu.ufc.br

** orientador@ufc.br

1 INTRODUÇÃO

A emergência espontânea de estruturas periódicas e quebras de simetria espacial em sistemas de reação-difusão, proposta por Alan Turing (Turing, 1952), fundamenta a compreensão teórica da morfogênese e da auto-organização não-linear (Murray, 2003). No modelo canônico de Schnakenberg (Schnakenberg, 1979), reações trimoleculares acopladas a taxas de difusão marcadamente desiguais ($D_v \gg D_u$) amplificam perturbações imperceptíveis na escala inicial ($\sim 10^{-3}$), organizando um meio quase uniforme em redes periódicas estáveis de manchas (*spots*).

Com o advento do aprendizado profundo científico, as Redes Neurais Informadas por Física (PINNs) (Raissi; Perdikaris; Karniadakis, 2019; Karniadakis *et al.*, 2021) despontaram como um paradigma contínuo sem malha, incorporando operadores diferenciais na função de perda via diferenciação automática (Baydin *et al.*, 2018). Embora demonstrem êxito notável em equações parabólicas lineares puramente dissipativas, as formulações *vanilla* de PINNs enfrentam entraves severos em **sistemas regidos por instabilidades temporais e seleção de ramos de bifurcação** (Wang; Paris; Perdikaris, 2024; Cuomo *et al.*, 2022).

Em simulações diretas (*forward*) de padrões de Turing, observa-se um paradoxo empírico: a rede neural atinge perdas residuais globais baixas ($\mathcal{L} < 10^{-3}$), porém o campo predito permanece uniforme e estacionário, suprimindo a formação de padrões. Estratégias convencionais de mitigação, como reponderação estática e imposição de condições iniciais rígidas (*hard IC*), mostram-se ineficazes.

Este artigo analisa rigorosamente os mecanismos subjacentes a esse colapso no modelo de Schnakenberg, fundamentando-se nas formulações teóricas e numéricas exatas de Pereira (2019). Demonstra-se que a **quebra da causalidade temporal**, potencializada pela **rigidez cinética** ($\kappa = 100$) e pelo **viés espectral**, aprisiona a rede na bacia de atração do estado homogêneo trivial. Como padrão de validação, revisita-se o **Método de Diferenças Finitas (MDF)** com **Direções Alternadas Implícitas (ADI)** linearizado de Pereira (2019), comprovando a superioridade da marcha causal sequencial.

2 DESENVOLVIMENTO

2.1 Modelo Matemático e Análise de Estabilidade Linear (LSA)

O sistema de reação-difusão de Schnakenberg em domínio bidimensional $\Omega = [0, L] \times [0, L]$ ($L = 1,0$) com condições de contorno de fluxo nulo (Neumann homogêneo) em $\partial\Omega$ é regido pelo par acoplado de EDPs (Schnakenberg, 1979; Pereira, 2019):

$$\frac{\partial u}{\partial t} = D_u \nabla^2 u + \kappa (a - u + u^2 v), \quad (1)$$

$$\frac{\partial v}{\partial t} = D_v \nabla^2 v + \kappa (b - u^2 v), \quad (2)$$

onde $u(x, y, t)$ representa a espécie ativadora, $v(x, y, t)$ a inibidora, D_u, D_v são os coeficientes difusivos, $a, b > 0$ são constantes cinéticas e κ é o parâmetro de escala de velocidade de reação. O ponto de equilíbrio estacionário homogêneo (u^*, v^*) é obtido anulando-se a cinética reativa e a difusão (Pereira, 2019):

$$u^* = a + b, \quad v^* = \frac{b}{(a + b)^2}. \quad (3)$$

Pela Análise Linear de Estabilidade (LSA), considerando perturbações $(\delta u, \delta v) \propto$

$e^{\lambda t} \cos(k_x x) \cos(k_y y)$, a matriz Jacobiana da reação avaliada em (u^*, v^*) é:

$$J = \begin{pmatrix} f_u & f_v \\ g_u & g_v \end{pmatrix} = \begin{pmatrix} \frac{b-a}{a+b} & (a+b)^2 \\ -\frac{2b}{a+b} & -(a+b)^2 \end{pmatrix}. \quad (4)$$

Para a ocorrência da instabilidade de Turing impulsionada por difusão diferencial, quatro condições são rigorosamente exigidas (Murray, 2003; Pereira, 2019): (i) $\text{Tr}(J) = f_u + g_v < 0$; (ii) $\det(J) = (a+b)^2 > 0$; (iii) $D_v f_u + D_u g_v > 0 \implies \frac{D_v}{D_u} > \frac{(a+b)^3}{b-a} > 1$; e (iv) $(D_v f_u + D_u g_v)^2 - 4D_u D_v (a+b)^2 > 0$.

Sob essas condições, o determinante do Jacobiano espacializado $J_k = \kappa J - k^2 \text{diag}(D_u, D_v)$ torna-se negativo para uma faixa contínua de números de onda $[k_1^2, k_2^2]$, centrada no modo crítico $k_c^2 \approx 135 \text{ rad}^2/\text{m}^2$. Perturbações nessa faixa sofrem amplificação exponencial $\propto e^{\lambda(k^2)t}$ com $\text{Re}(\lambda) > 0$, quebrando a simetria espacial e saturando na rede estável de *spots*.

2.2 Formulação da PINN e Arquitetura da Rede Neural

A formulação PINN aproxima o vetor de estados contínuo $\hat{\mathbf{w}}_\theta = (\hat{u}_\theta, \hat{v}_\theta)^T$ por meio de um Perceptron Multicamadas (*Pure MLP*) profundo no espaço-tempo global $\mathbf{z} = (x, y, t)^T \in \Omega \times [0, T]$:

$$\mathbf{h}^{(0)} = \mathbf{z} \in \mathbb{R}^3, \quad (5)$$

$$\mathbf{h}^{(\ell)} = \sigma(\mathbf{W}^{(\ell)} \mathbf{h}^{(\ell-1)} + \mathbf{b}^{(\ell)}), \quad \ell = 1, \dots, L, \quad (6)$$

$$\hat{\mathbf{w}}_\theta(\mathbf{z}) = \mathbf{W}^{(L+1)} \mathbf{h}^{(L)} + \mathbf{b}^{(L+1)} \in \mathbb{R}^2, \quad (7)$$

onde $L = 5$ camadas ocultas com largura de 128 neurônios cada, $\mathbf{W}^{(\ell)} \in \mathbb{R}^{128 \times 128}$, $\mathbf{b}^{(\ell)} \in \mathbb{R}^{128}$, e $\sigma(\cdot)$ denota a função de ativação não-linear. Adotou-se $\sigma(z) = \tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}} \in C^\infty(\mathbb{R})$, essencial para a existência e continuidade das segundas derivadas espaciais no cômputo dos Laplacianos $\nabla^2 \hat{u}$ e $\nabla^2 \hat{v}$ via autograd. A rede totaliza $512 + 4 \times 16 \cdot 512 + 258 = 66.818$ parâmetros treináveis, inicializados pelo método de Xavier Normal.

A função de perda multiobjetivo minimiza os resíduos da EDP, da condição inicial e de contorno:

$$\mathcal{L}(\theta) = \frac{1}{N_f} \sum_{i=1}^{N_f} (\|\mathcal{R}_u\|^2 + \|\mathcal{R}_v\|^2) + \frac{\lambda_{ic}}{N_0} \sum_{j=1}^{N_0} (\|\hat{u}_0 - u_0\|^2 + \|\hat{v}_0 - v_0\|^2) + \frac{\lambda_{bc}}{N_b} \sum_{k=1}^{N_b} (\|\nabla \hat{u} \cdot \mathbf{n}\|^2 + \|\nabla \hat{v} \cdot \mathbf{n}\|^2), \quad (8)$$

onde $\mathcal{R}_u = \hat{u}_t - D_u \nabla^2 \hat{u} - \kappa(a - \hat{u} + \hat{u}^2 \hat{v})$ e $\mathcal{R}_v = \hat{v}_t - D_v \nabla^2 \hat{v} - \kappa(b - \hat{u}^2 \hat{v})$.

Os parâmetros físicos e de discretização foram adotados exatamente como descritos na tese de Pereira (2019, Tabela 27 e Eq. 2.31), listados na Tabela 1. O domínio espacial é o quadrado unitário $\Omega = [0, 1] \times [0, 1]$ e o horizonte temporal é $t \in [0, 2, 0 \text{ s}]$. A condição inicial consiste na perturbação gaussiana localizada central:

$$u(x, y, 0) = u^* + 10^{-3} e^{-100 \left[\left(x - \frac{1}{3}\right)^2 + \left(y - \frac{1}{2}\right)^2 \right]}, \quad v(x, y, 0) = v^*. \quad (9)$$

O treinamento foi executado por 20.000 épocas com o otimizador Adam ($\eta_0 = 10^{-3}$) acoplado a um agendador *Cosine Annealing* até $\eta_{\min} = 10^{-5}$ em GPU NVIDIA RTX 3050 (1.169,48 s de execução).

Tabela 1 — Parâmetros físicos, do domínio e de rede adotados conforme Pereira (2019).

Parâmetro	Descrição Física / Numérica	Valor Adotado
Ω	Domínio espacial bidimensional	$[0, 1] \times [0, 1]$
T	Horizonte temporal de simulação	2,0 s
a, b, κ	Constantes cinéticas da reação	$a = 0,1305, b = 0,7695, \kappa = 100,0$
D_u, D_v	Coeficientes de difusão (D_1, D_2)	$D_u = 0,05, D_v = 1,0 (D_v/D_u = 20)$
(u^*, v^*)	Ponto de equilíbrio homogêneo	(0,9000, 0,9500)
N_f, N_0, N_b	Pontos de amostragem (EDP / IC / BC)	10.000, 2.500, 2.000
Arquitetura	Pure MLP (5 camadas ocultas $\times$ 128 neurônios)	66.818 parâmetros treináveis
Ativação / Otimizador	Função $\sigma(z) = \tanh(z)$, Adam + Cosine Annealing	20.000 épocas (1.169,48 s na GPU)

2.3 Mecanismos Físico-Matemáticos da Falha da PINN

A convergência espúria da PINN decorre de três patologias interdependentes:

2.3.1 1. Quebra da Causalidade Temporal e Dissipação Artificial

Em sistemas físicos evolutivos, o estado em t_2 depende unicamente da trajetória causal em $t_1 < t_2$. Em uma PINN contínua, contudo, a perda é integrada simultaneamente em todo o cilindro $\Omega \times [0, T]$. Como (u^*, v^*) satisfaz $f(u^*, v^*) = 0$ e $\nabla^2 u^* = 0$, ele zera os resíduos da EDP ($\mathcal{R}_u \equiv 0, \mathcal{R}_v \equiv 0$). Para minimizar o resíduo global, o otimizador força $\nabla^2 u \rightarrow 0$. Esses gradientes futuros retropropagam-se pelos pesos compartilhados até $t = 0$, atuando como uma **viscosidade numérica artificial que aniquila o crescimento exponencial da perturbação inicial** (Wang; Paris; Perdikaris, 2024).

2.3.2 2. Rigidez Cinética e Desbalanço no Hessiano da Perda

A taxa $\kappa = 100$ induz uma escala reativa $\tau_{\text{reac}} \sim \kappa^{-1} = 0,01$ s muito menor que a difusiva $\tau_{\text{dif}} \sim L^2/D_u = 20$ s. No gradiente $\nabla_{\theta} \mathcal{L}_{\text{pde}} \propto \kappa \nabla_{\theta} f(u, v) - D_u \nabla_{\theta} (\nabla^2 u)$, o termo reativo domina a magnitude dos gradientes, forçando $f(u, v) = 0$ antes que o transporte difusivo possa segregar espécies. O espectro do Hessiano torna-se mal condicionado, estagnando a rede no atrator homogêneo.

2.3.3 3. Viés Espectral contra Modos de Turing

Pelo Princípio da Frequência (Rahaman *et al.*, 2019; Wang; Wang; Perdikaris, 2021), MLPs aprendem baixas frequências espaciais muito antes de resolver oscilações rápidas. Como o modo crítico reside na cauda de alta frequência ($k_c^2 \approx 135 \text{ rad}^2/\text{m}^2$), a rede atenua ativamente as ondulações espaciais necessárias aos padrões.

2.4 A Solução Clássica de Referência: MDF ADI Linearizado de Pereira (2019)

Para eliminar a rigidez e manter a causalidade, Pereira (2019) formulou um esquema **semi-implícito linearizado** no contexto do MDF acoplado ao algoritmo ADI de Peaceman-Rachford ($n \rightarrow n + 1/2 \rightarrow n + 1$):

$$\left(I - \frac{D_1 \Delta t}{2} \delta_x^2 \right) [X]^{n+1/2} = \left(I + \frac{D_1 \Delta t}{2} \delta_y^2 \right) [X]^n + \frac{\Delta t}{2} \kappa \tilde{f}^{n+1/2}, \quad (10)$$

$$\left(I - \frac{D_1 \Delta t}{2} \delta_y^2 \right) [X]^{n+1} = \left(I + \frac{D_1 \Delta t}{2} \delta_x^2 \right) [X]^{n+1/2} + \frac{\Delta t}{2} \kappa \tilde{f}^{n+1/2}, \quad (11)$$

onde $\tilde{f}^{n+1/2}$ é o termo de reação predito linearizado em $t^{n+1/2}$ por (Pereira, 2019):

$$[\tilde{X}] = \frac{[X]\Delta t\kappa - 2[X] - D_1\Delta t\nabla^2[X] - \Delta t\kappa a}{[X][Y]\Delta t\kappa - 2}, \quad [\tilde{Y}] = \frac{-[Y]\frac{\Delta t}{2}[X]^2\kappa + [Y] + D_2\frac{\Delta t}{2}\nabla^2[Y] + \frac{\Delta t\kappa}{2}b}{1 + \frac{\Delta t\kappa}{2}[X]^2}. \quad (12)$$

O algoritmo MDF ADI resolve sistemas tridiagonais $\mathcal{O}(N)$ via Algoritmo de Thomas, garantindo **estabilidade incondicional**, **ordem** $\mathcal{O}(\Delta t^2)$ e preservação causal (Pereira, 2019).

2.5 Resultados Experimentais e Confronto Direto

A Figura 1(a) ilustra o paradoxo das perdas durante as 20.000 épocas: a perda total decresceu para $1,95 \times 10^{-4}$, com $\mathcal{L}_{ic} = 4,02 \times 10^{-8}$. Contudo, a Figura 1(b) revela que a amplitude de heterogeneidade $\|u(t) - u^*\|_{L_2}$ decaiu para zero na PINN, contra o crescimento exponencial e saturação nos *spots* pelo MDF ADI ($\|u - u^*\|_{L_2} \approx 0,61$).




Figura 1 — Diagnóstico de causalidade: (a) Trajetórias de perda da PINN ao longo de 20.000 épocas; (b) Evolução temporal de $\|u(t) - u^*\|_{L_2}$, confrontando o crescimento exponencial do MDF ADI com o colapso homogêneo da PINN.

A Figura 2 apresenta o confronto direto nos instantes $t \in \{0,02, 0,41, 2,00\}$ s. O solucionador MDF ADI registra a expansão da perturbação em $t = 0,02$ s, a quebra de simetria em $t = 0,41$ s e a rede de spots em $t = 2,00$ s ($u \in [0,2134, 2,8305]$), enquanto a PINN permanece estática em $u \approx 0,9000$, resultando em erro relativo de 60,85% e erro pontual máximo de 1,9307 (Tabela 2).

Tabela 2 — Confronto metodológico e quantitativo: PINN Vanilla vs. MDF ADI Linearizado (Pereira, 2019).

Métrica / Propriedade	PINN Vanilla (20.000 Épocas)	MDF ADI Linearizado (Pereira, 2019)
Tratamento Temporal	Espaço-tempo contínuo $\Omega \times [0, T]$	Marcha causal sequencial ($t^n \rightarrow t^{n+1}$)
Causalidade Física	Violada (gradientes futuros ativos)	Preservada estritamente
Sensibilidade a $\epsilon \sim 10^{-3}$	Amortecida (atração homogênea)	Amplificada $\propto e^{\lambda t}$ (instabilidade real)
Solução de Sistemas Espaciais	Diferenciação automática (66.818 pesos)	Algoritmo de Thomas $\mathcal{O}(N)$ tridiagonal
Perda Residual / Erro Final	$\mathcal{L}_{total} = 1,95 \times 10^{-4}$ (estagnada)	Ordem $\mathcal{O}(\Delta t^2)$, convergente
Tempo de GPU / CPU	1.169,48 s (19,49 minutos na GPU)	9,59 segundos (malha 128×128)
Faixa do Ativador $u(t = 2,0)$	$u \in [0,8994, 0,9001]$ (Falha total)	$u \in [0,2134, 2,8305]$ (Spots perfeitos)

MDF ADI x PINN: Campo de Concentração do Ativador $u(x,y,t)$




Figura 2 — Confronto espaço-temporal direto 2×3 : Solução exata MDF ADI de Pereira (2019) (linha superior) versus predição da PINN Vanilla após 20.000 épocas (linha inferior) para $t \in \{0,02, 0,41, 2,00\}$ s.

3 CONSIDERAÇÕES FINAIS

A investigação computacional realizada comprova que o colapso de PINNs *vanilla* na simulação de padrões de Turing decorre de uma **patologia intrínseca de otimização oriunda da quebra de causalidade temporal e rigidez cinética**. Ao colocalizar pontos em todo o horizonte $[0, T]$ simultaneamente, a retropropagação transforma o estado estacionário plano em um atrator espúrio de perda residual quase nula ($\sim 10^{-4}$), dissipando ativamente os modos instáveis físicos.

Em contrapartida, o método **MDF ADI Linearizado** de Pereira (2019) reafirma a imprescindibilidade de estruturas causais com marcha sequencial no tempo, resolvendo a bifurcação em apenas 9,59 s com estabilidade incondicional. Conclui-se que, para tornar PINNs viáveis em problemas de morfogênese e instabilidade, é imperativo incorporar **pesagens causais estritas** ($\mathcal{L}_{\text{causal}}$) (Wang; Paris; Perdikaris, 2024), **PINNs discretas por marcha temporal** ou esquemas de **homotopia em κ** .

REFERÊNCIAS

- BAYDIN, Atilim Gunes *et al.* Automatic differentiation in machine learning: a survey. **Journal of Machine Learning Research**, v. 18, n. 153, p. 1–43, 2018. Disponível em <http://jmlr.org/papers/v18/17-468.html>.
- CUOMO, Salvatore *et al.* Scientific Machine Learning through Physics-Informed Neural Networks: Where we are and What's next. **Journal of Scientific Computing**, Springer, v. 92, n. 3, p. 88, 2022. DOI: 10.1007/s10915-022-01939-z.
- KARNIADAKIS, George Em *et al.* Physics-informed machine learning. **Nature Reviews Physics**, Nature Publishing Group, v. 3, n. 6, p. 422–440, 2021. DOI: 10.1038/s42254-021-00314-5.

MURRAY, James Dickson. **Mathematical Biology II: Spatial Models and Biomedical Applications**. New York: Springer-Verlag, 2003. v. 18.

PEREIRA, Ricardo Reis. **Métodos de Diferenças Finitas para Problemas de Difusão e Reação Não Lineares**. 2019. Tese (Doutorado) – Laboratório Nacional de Computação Científica (LNCC), Petrópolis, RJ.

RAHAMAN, Nasim *et al.* On the Spectral Bias of Neural Networks. **Proceedings of Machine Learning Research**, PMLR, v. 97, p. 5301–5310, 2019.

RAISSI, Maziar; PERDIKARIS, Paris; KARNIADAKIS, George Em. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. **Journal of Computational Physics**, Elsevier, v. 378, p. 686–707, 2019. DOI: 10.1016/j.jcp.2018.10.045.

SCHNAKENBERG, Jürgen. Simple chemical reaction systems with limit cycle behaviour. **Journal of Theoretical Biology**, Elsevier, v. 81, n. 3, p. 389–400, 1979.

TURING, Alan Mathison. The chemical basis of morphogenesis. **Philosophical Transactions of the Royal Society of London. Series B, Biological Sciences**, The Royal Society, v. 237, n. 641, p. 37–72, 1952.

WANG, Sifan; PARIS, Paris; PERDIKARIS, Paris. Respecting causality is all you need for training physics-informed neural networks. **Computer Methods in Applied Mechanics and Engineering**, Elsevier, v. 421, p. 116776, 2024.

WANG, Sifan; WANG, Hanwei; PERDIKARIS, Paris. On the eigenvector bias of Fourier features in physics-informed neural networks. **Computer Methods in Applied Mechanics and Engineering**, Elsevier, v. 384, p. 113938, 2021.